



UNIVERSITÀ  
DEGLI STUDI  
DI PADOVA

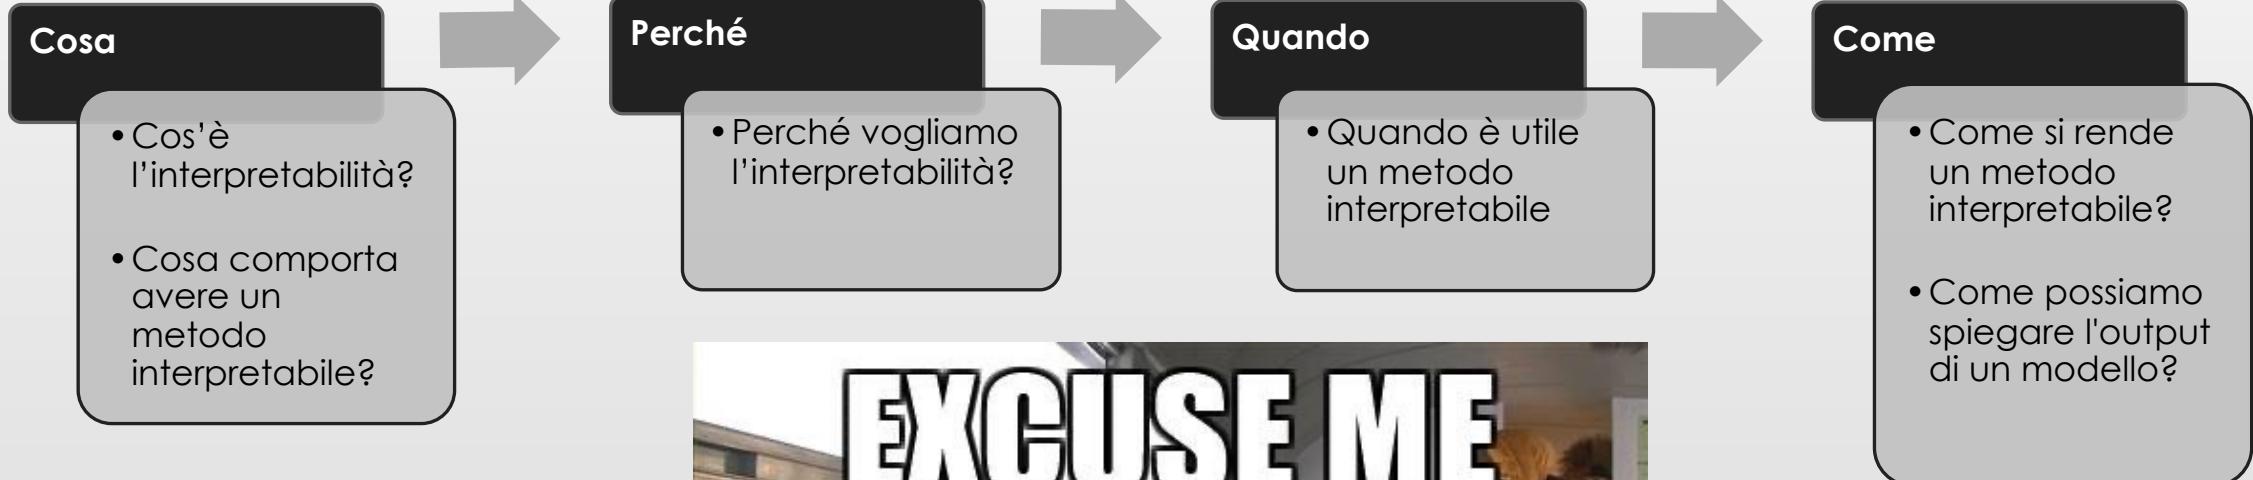


DIPARTIMENTO  
**MATEMATICA**

# Interpretabilità nel Machine Learning

Mirko Polato, PhD  
[mpolato@math.unipd.it](mailto:mpolato@math.unipd.it)

# Cosa vedremo oggi

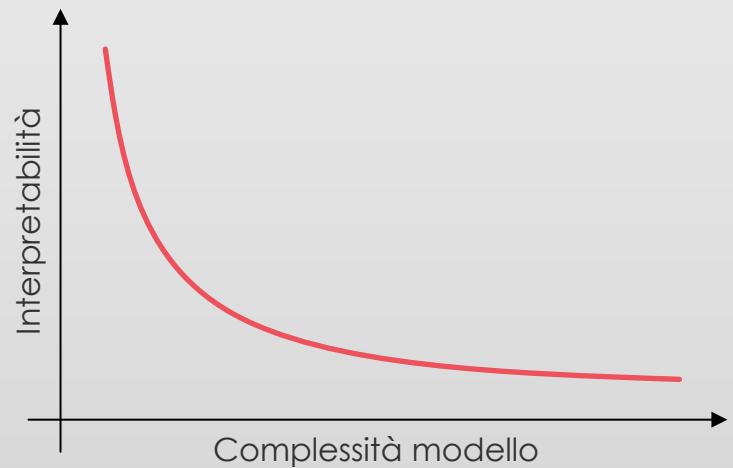


Alcuni dei contenuti di questa presentazione sono stati estrapolati da **Molnar (2018)**

# Cos'è l'interpretabilità?

**"L'interpretabilità è il grado con cui un umano comprende la causa di una decisione"**

Miller (2017)



Interpretabilità

Incompletezza nel formalizzare il problema

Curiosità

# Interpretabilità “in action”

- **Applicazioni con conseguenze significative:** giustizia, sanità, self-driving cars...
- **Applicazioni mediche:** una diagnosi deve poter essere spiegata
- **Controllo su eventuali bias:** modelli ML che discriminano minoranze (fairness)
- **Recommender System:** spiegare la raccomandazione aiuta nel mantenere fiducia nel sistema
- **GDPR:** decisioni prese da machine con conseguenze legali devono essere spiegate

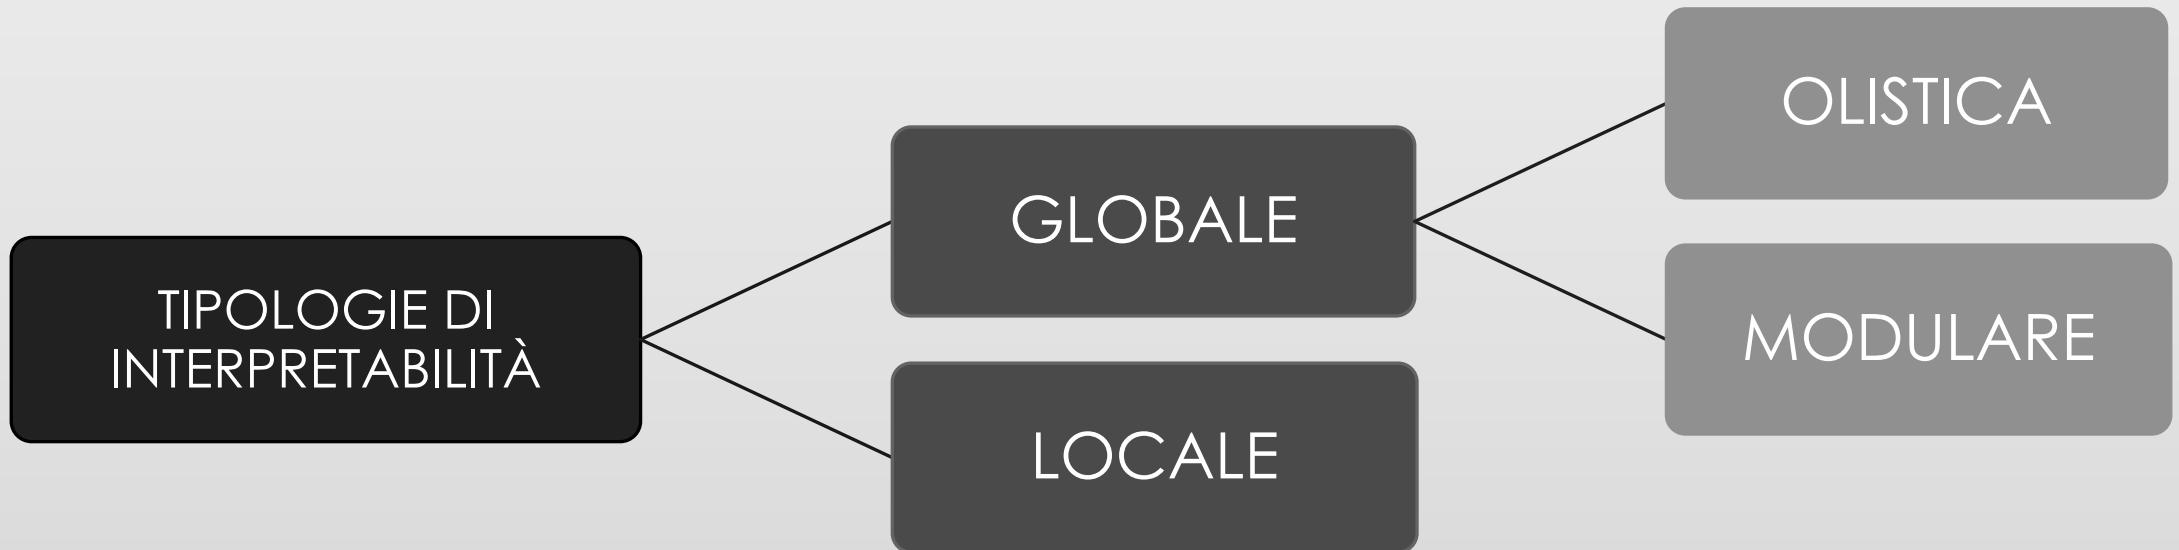
# Quando è utile?

## UTILE/DESIDERABILE

- Conoscere il ‘perché’ è parte fondamentale del problema
- **Debugging**
- Incrementare l'**accettazione sociale**
- **Fairness** check
- **Trust**
- **Privacy**
- Il modello **non** ha un particolare **impatto**
- Il problema è **ben conosciuto**
- Evitare **manipolazioni**

## NON NECESSARIA

# Tipi di interpretabilità



# Properietà

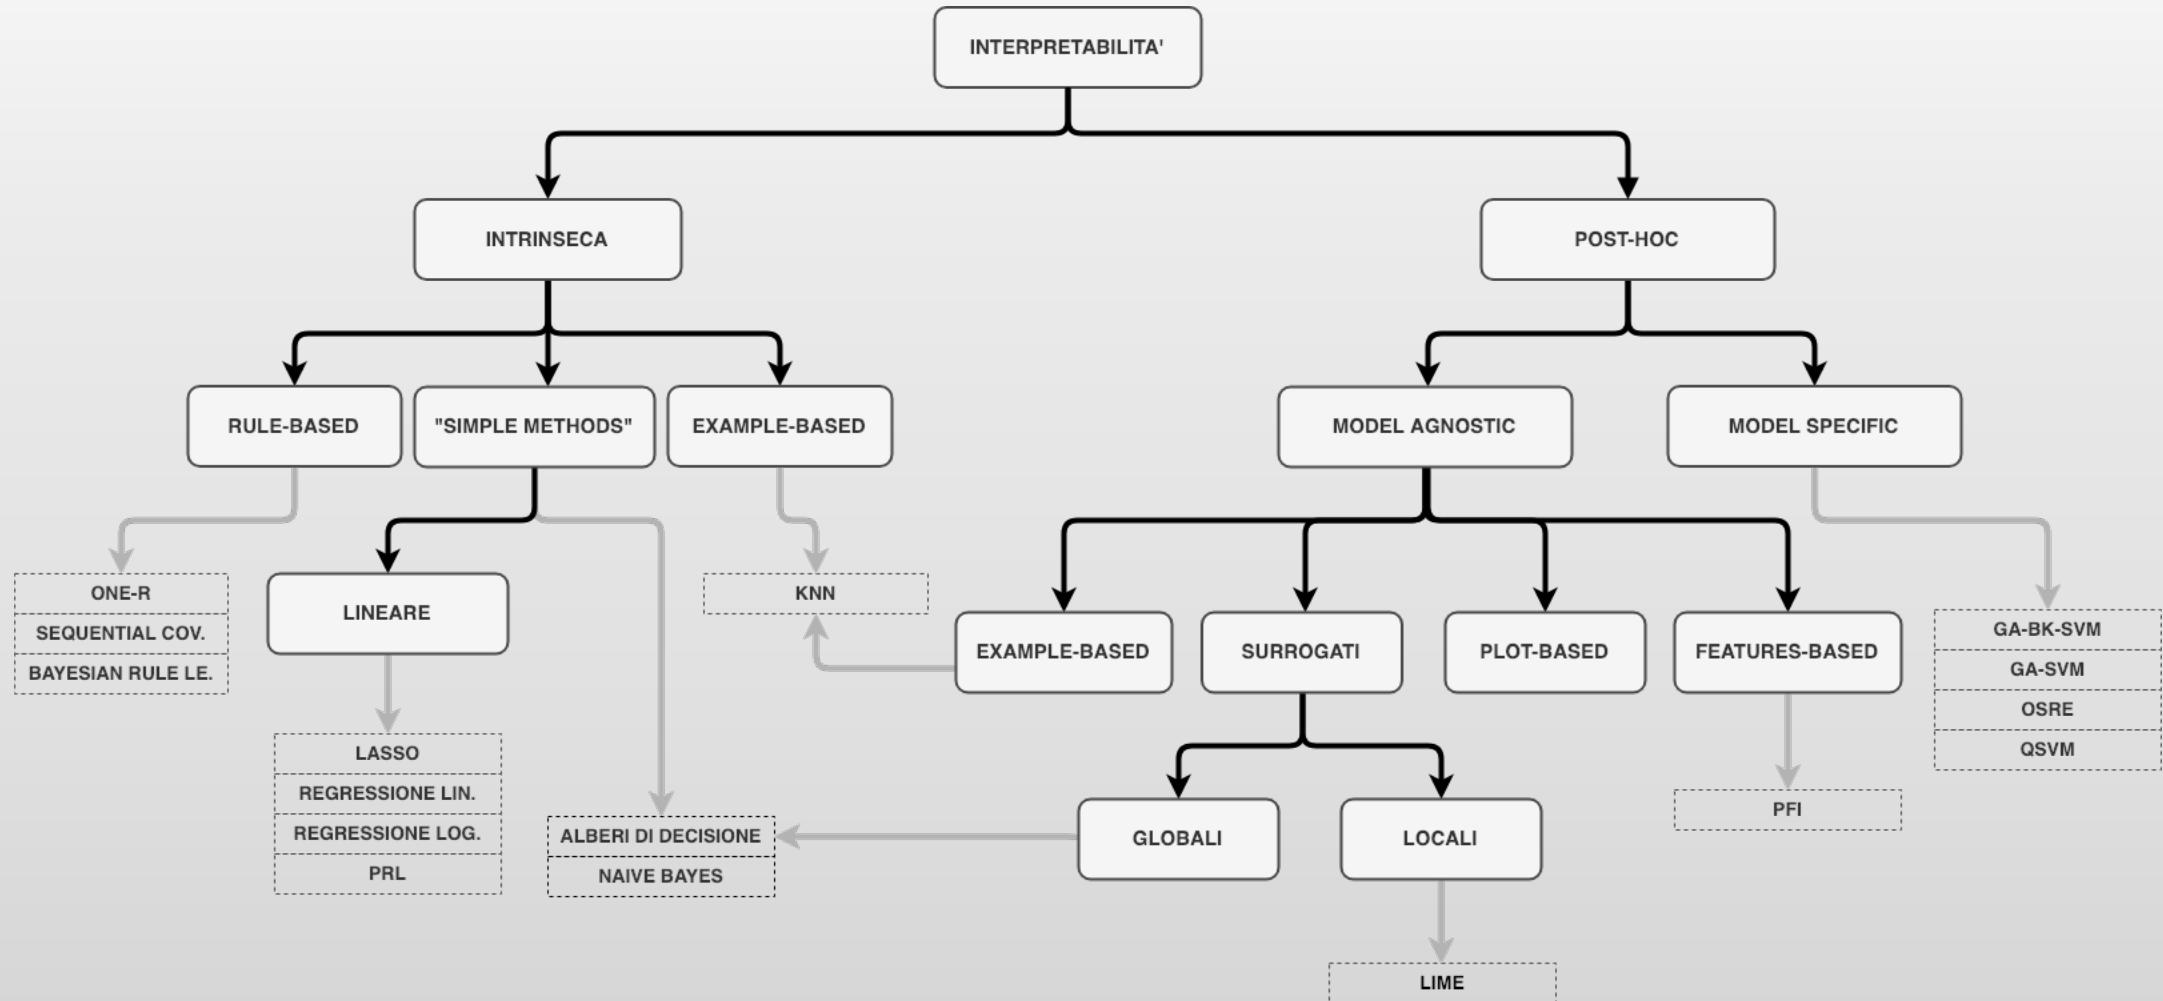
## Explanation methods

- Espressività
- Translucenza
- Portabilità
- Complessità computazionale

## Individual explanation

- Accuratezza
- Fedeltà
- Stabilità
- Comprensibilità

# Tassonomia



# Come valutare un metodo interpretabile



**Valutazione a livello applicazione  
(task reale)**

La spiegazione è testata sul campo direttamente dagli utenti (esperti)



**Valutazione a livello umano  
(task semplificato)**

Semplificazione della valutazione a livello applicazione (utenti non esperti)

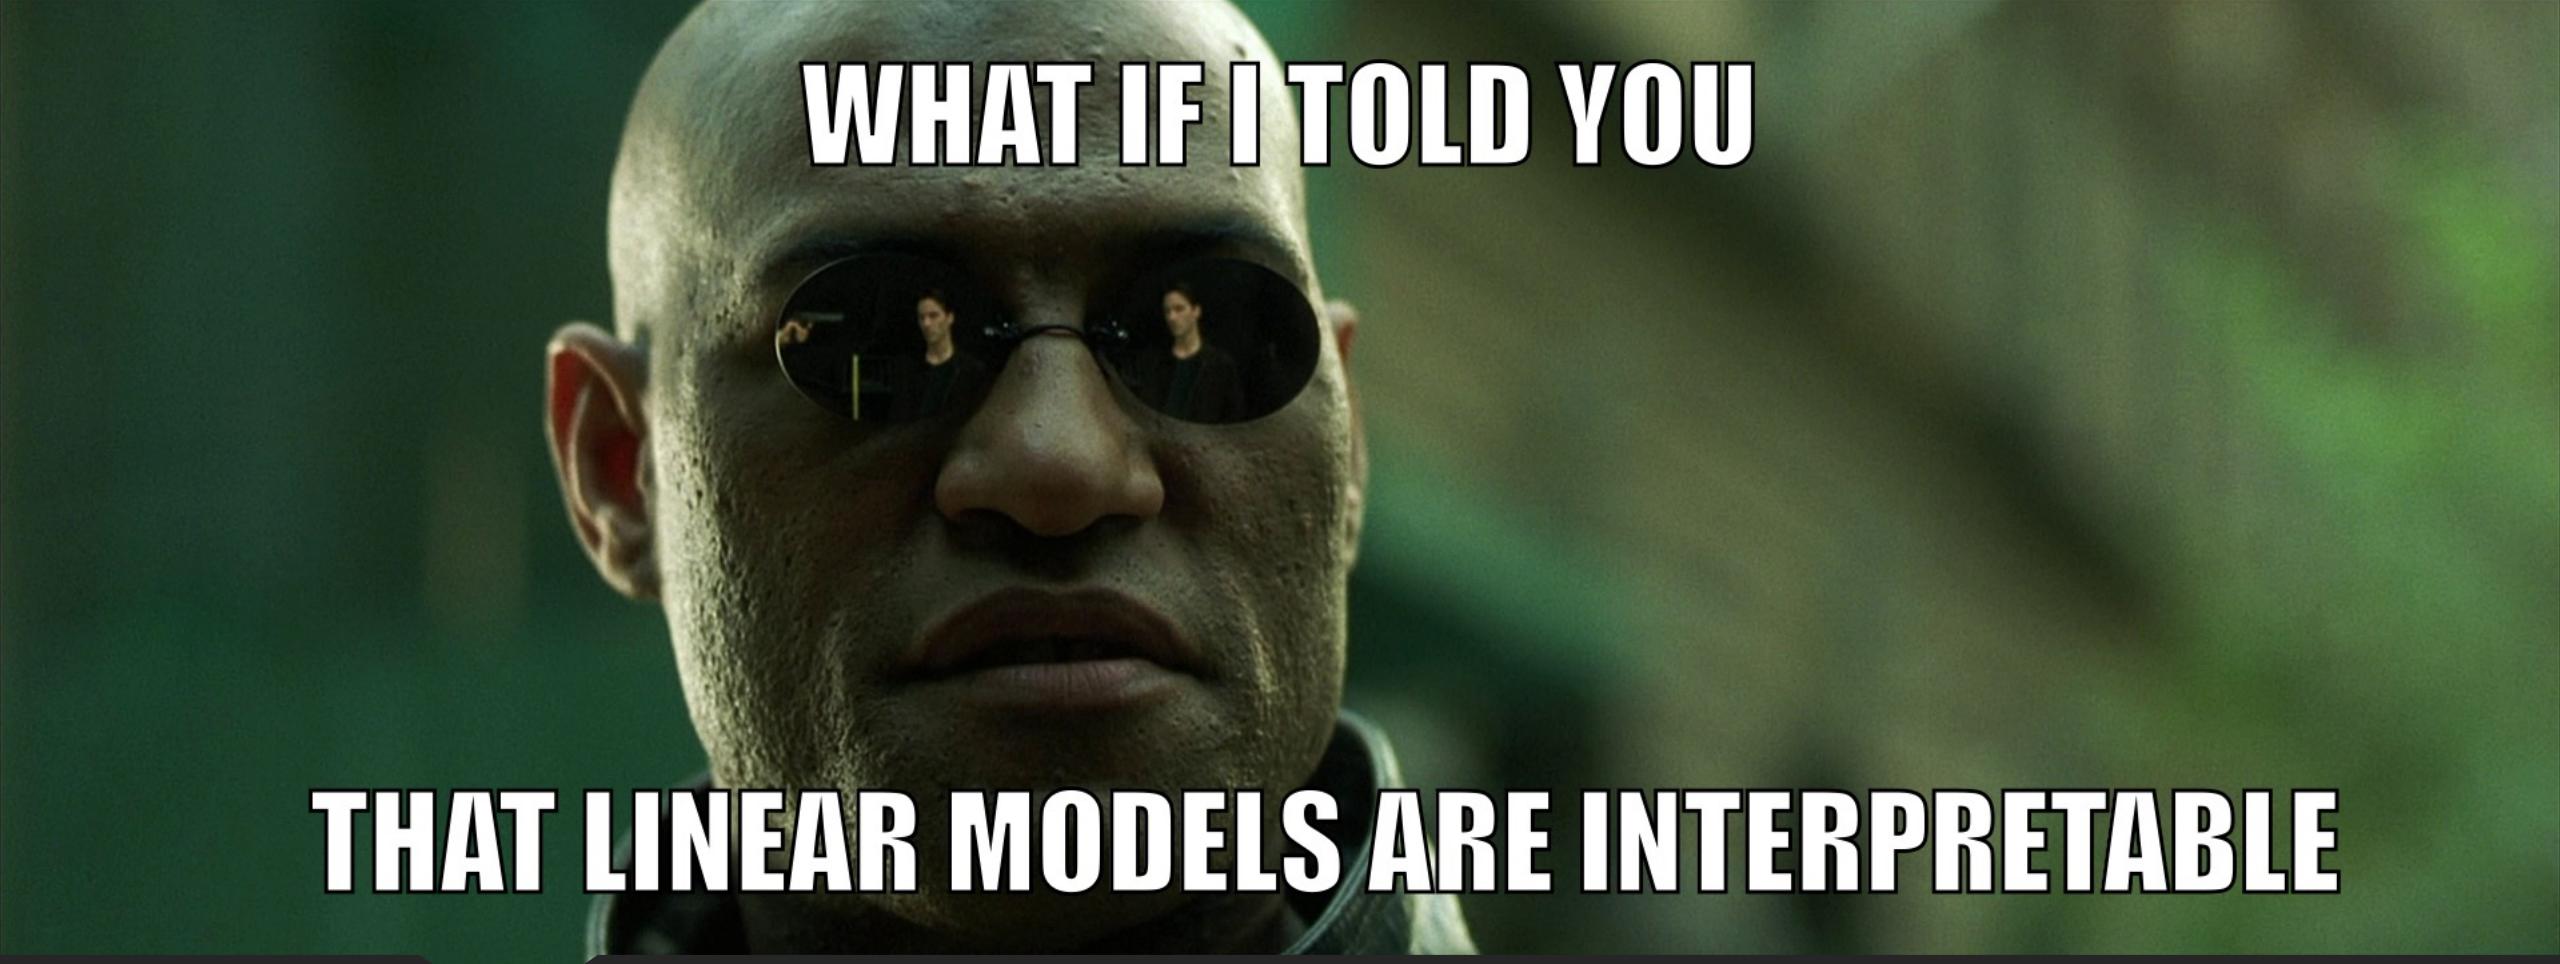


**Valutazione a livello funzionale  
(task proxy)**

Non richiede l'intervento umano. Utile a monte di una precedente valutazione a livello umano.

# Metodi nel “dettaglio”

- Regressione Lineare
- Alberi di decisione
  - metodo intrinsecamente interpretabile
  - metodo surrogato
- PRL: Preference and rule learning [Polato (2019)]
- GA-BK-SVM [Polato (2018a, 2018b)]

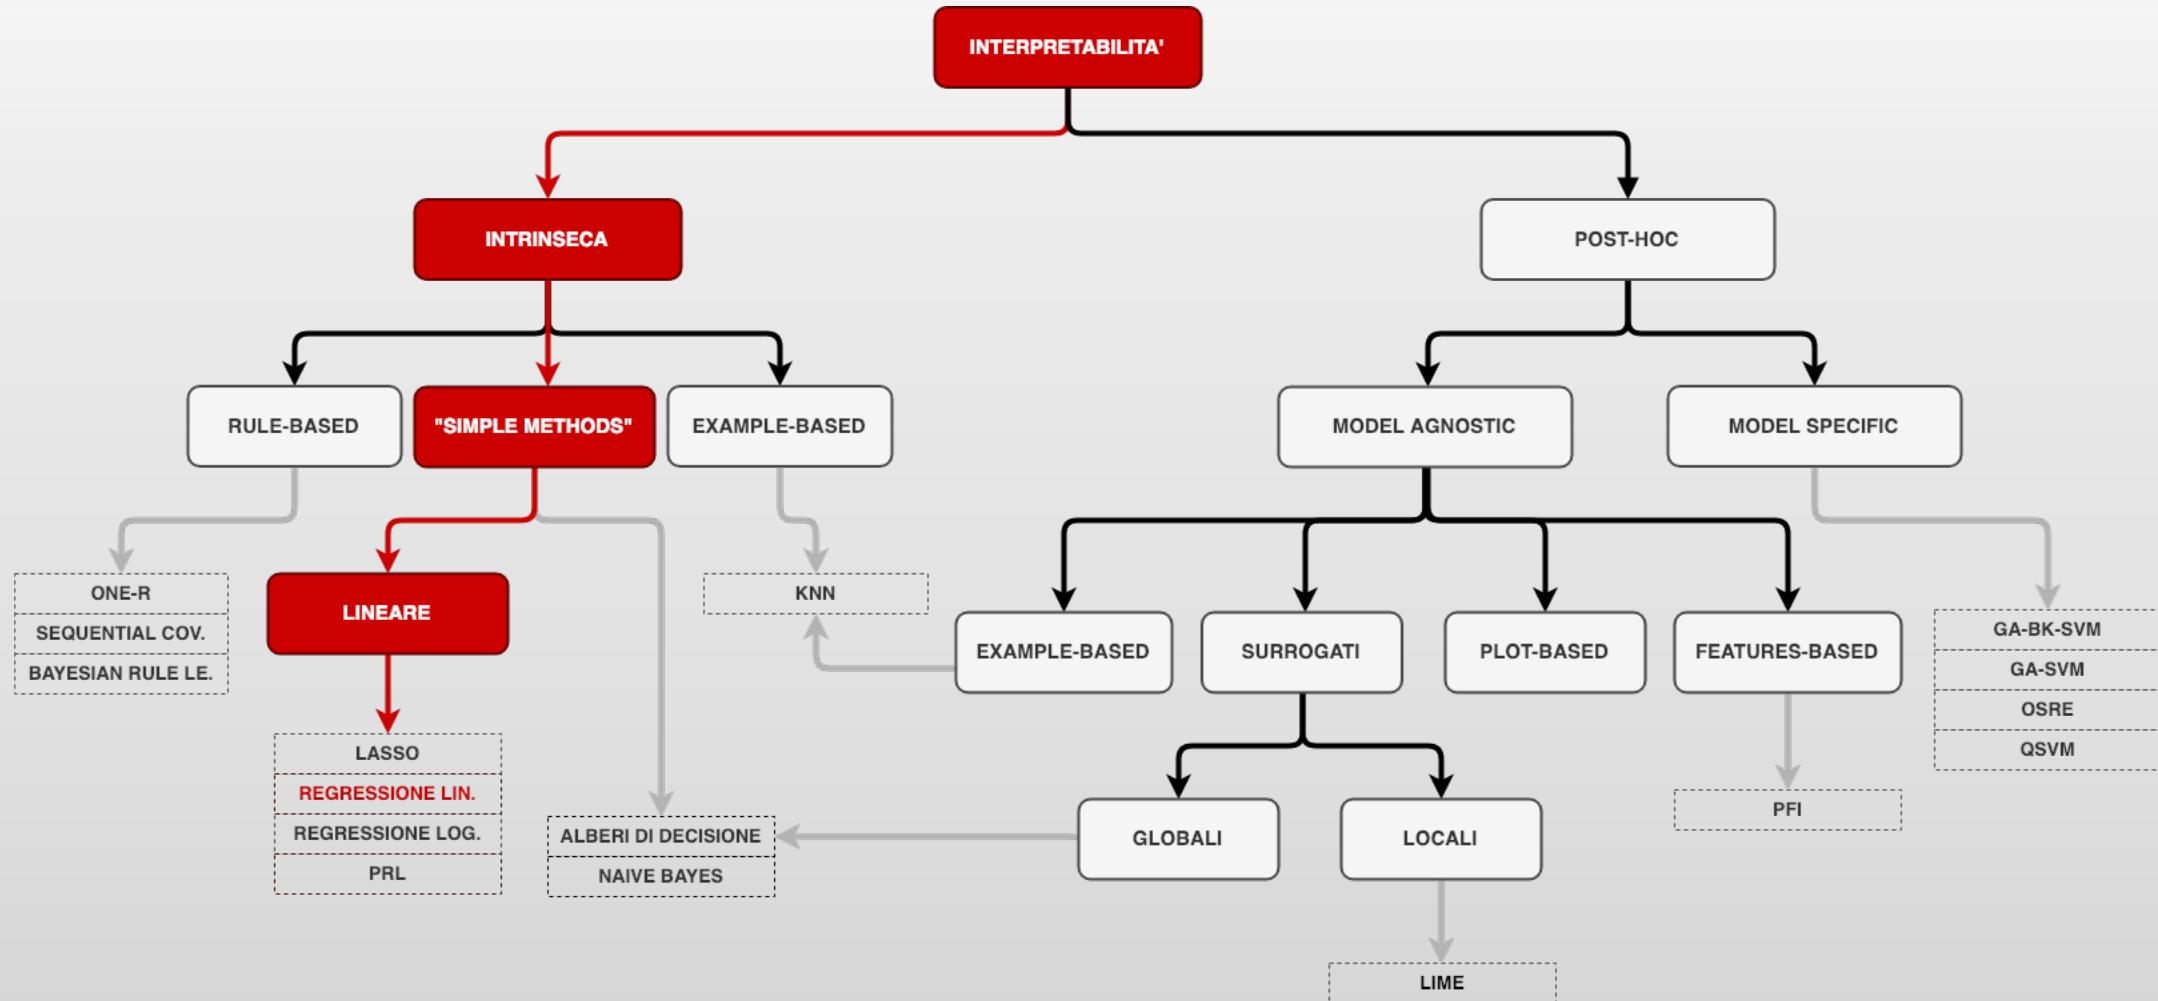


**WHAT IF I TOLD YOU**

**THAT LINEAR MODELS ARE INTERPRETABLE**

**Regressione lineare**

# Regressione Lineare

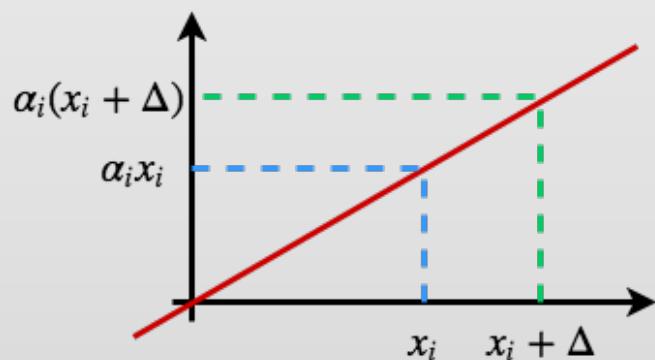


# Interpretare un regressore lineare

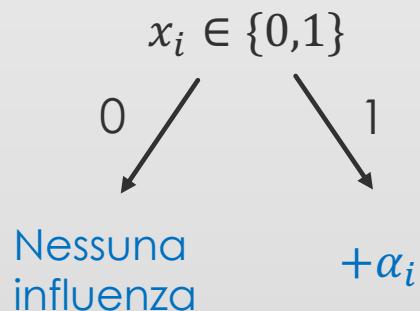
Per un'istanza  $(\mathbf{x}, y)$ , con  $\mathbf{x} \in \mathbb{R}^p$  e  $y \in \mathbb{R}$  il modello appreso ha la seguente forma

$$y = \alpha_0 + \alpha_1 x_1 + \cdots + \alpha_p x_p$$

## Feature a valori reali



## Feature binaria (\*)



## Intercetta

Significativa su esempi standardizzati

y dell'esempio standard

(\*) può essere generalizzato a feature categoriche

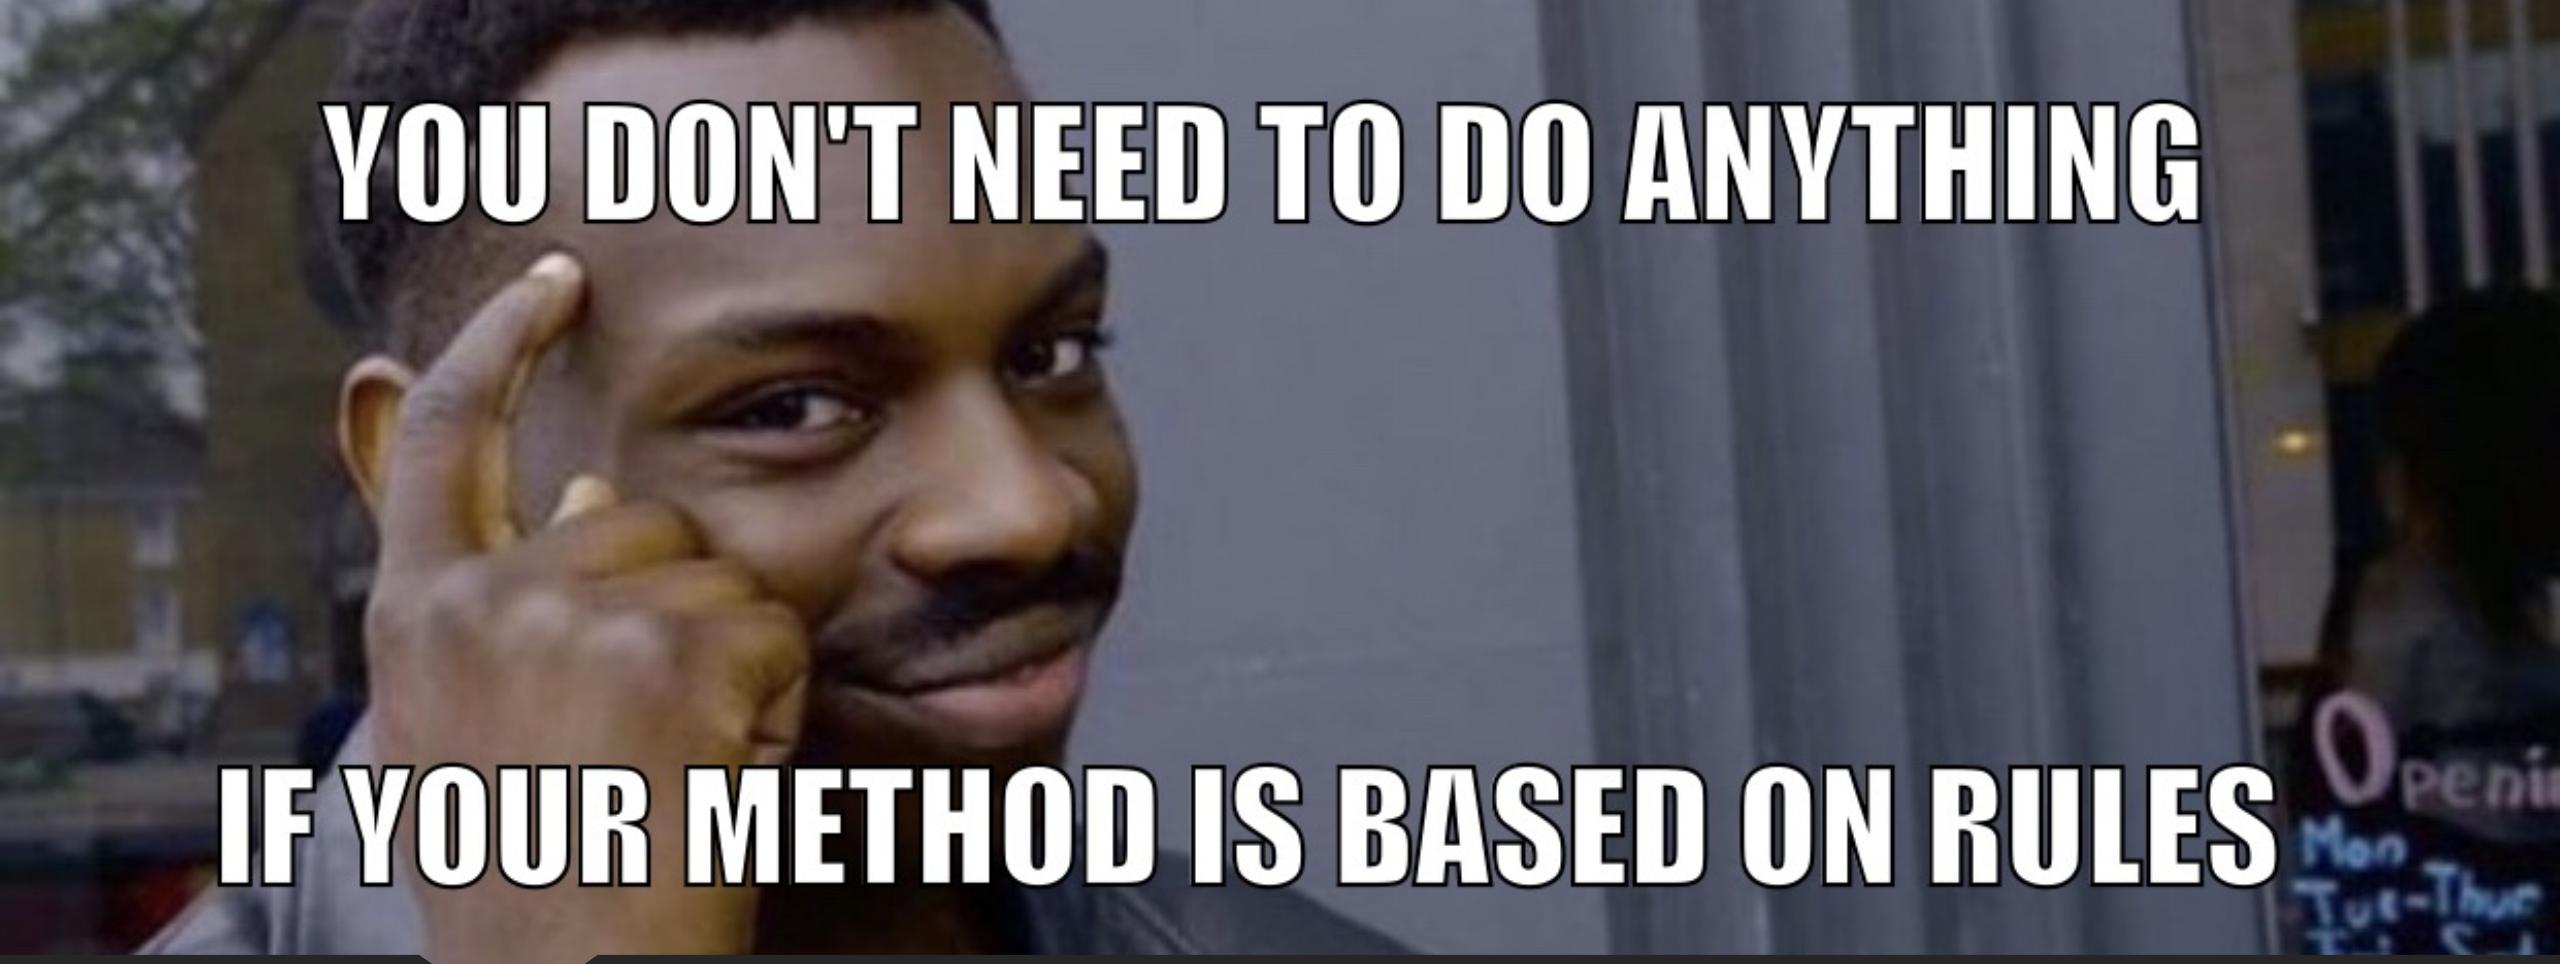
# Regressione lineare: pro e contro

## PROS

- **Trasparente**
- **Semplice**
- Tra i più conosciuti e implementato in molti framework
- Esistono molte **estensioni**/varianti: LASSO, GLM, SLM...

- **Solo relazioni lineari**
- Generalmente non ha performance allo stato dell'arte
- L'**interpretazione** potrebbe **non** essere **intuitiva**

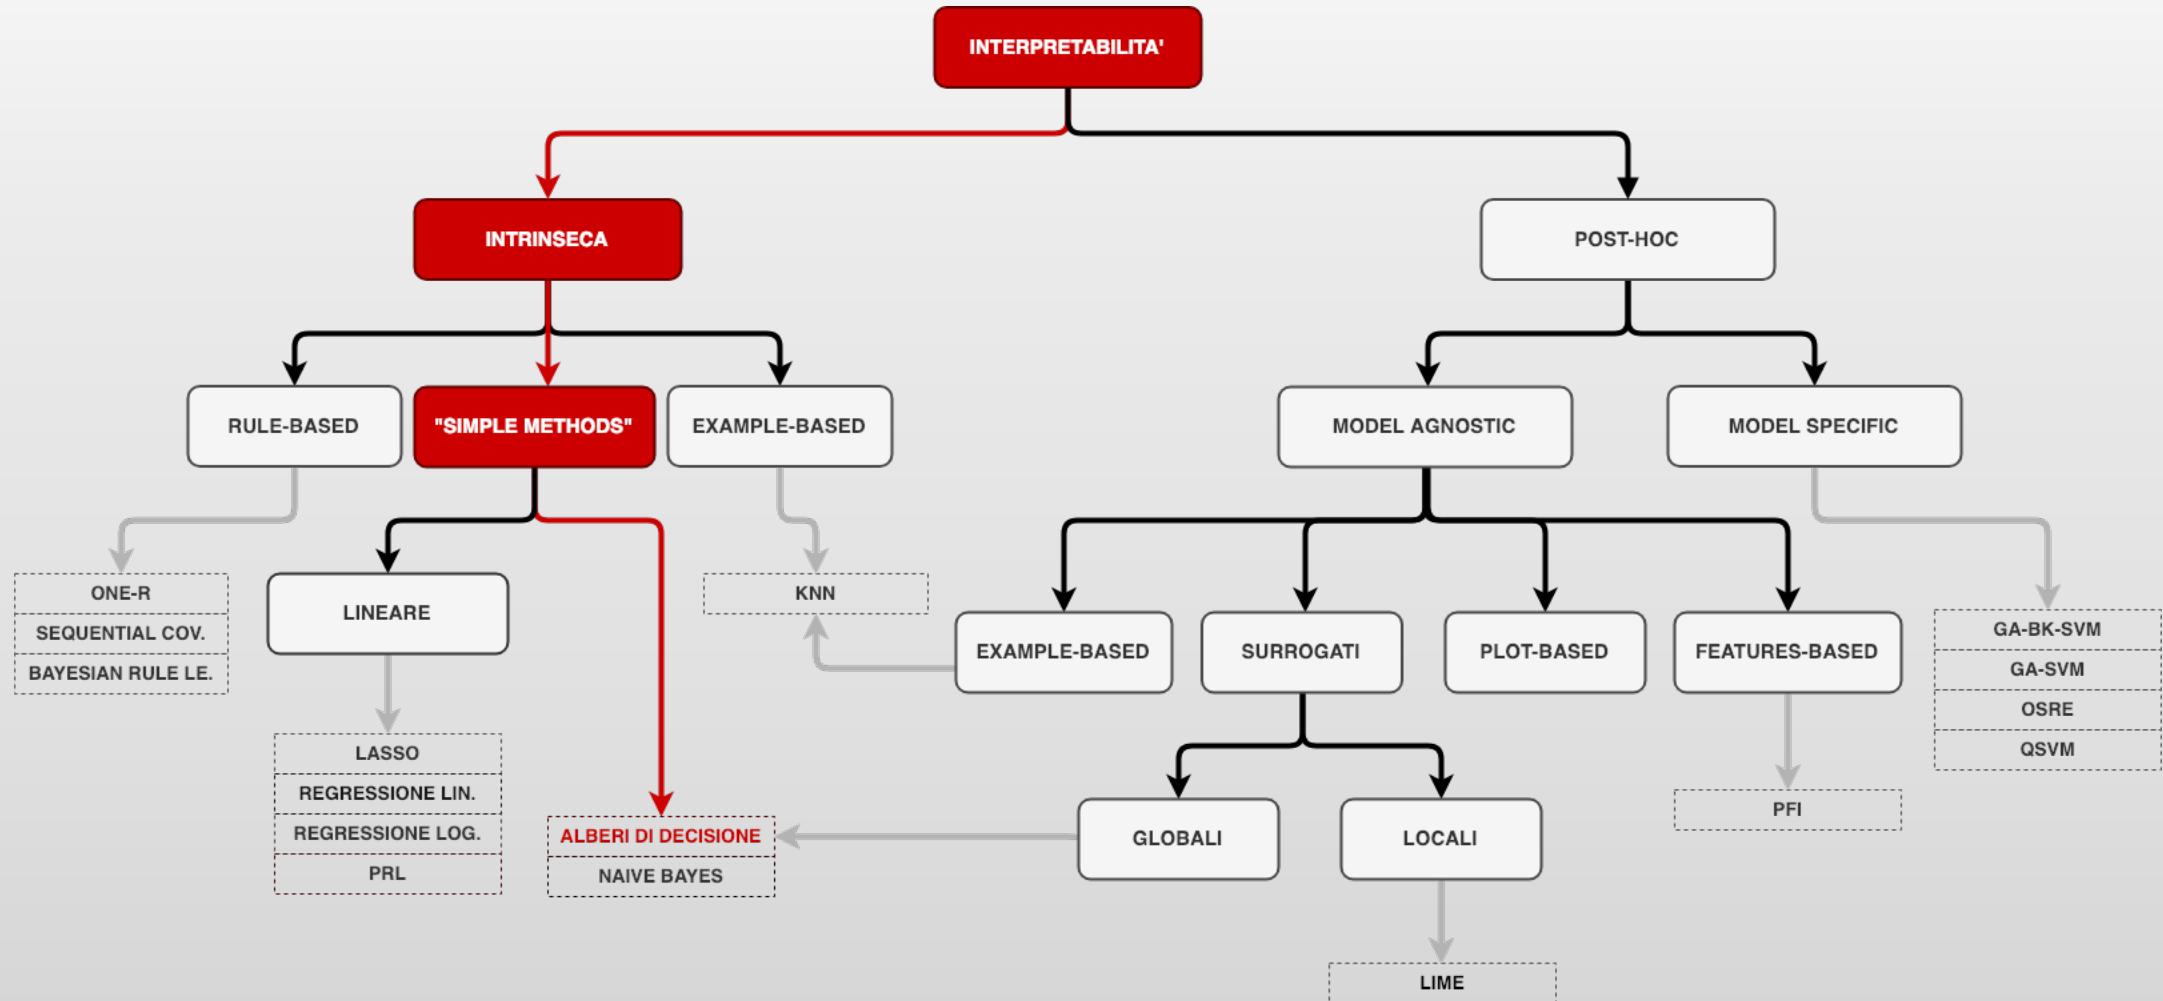
## CONS



**YOU DON'T NEED TO DO ANYTHING  
IF YOUR METHOD IS BASED ON RULES**

## Alberi di decisione

# Alberi di decisione

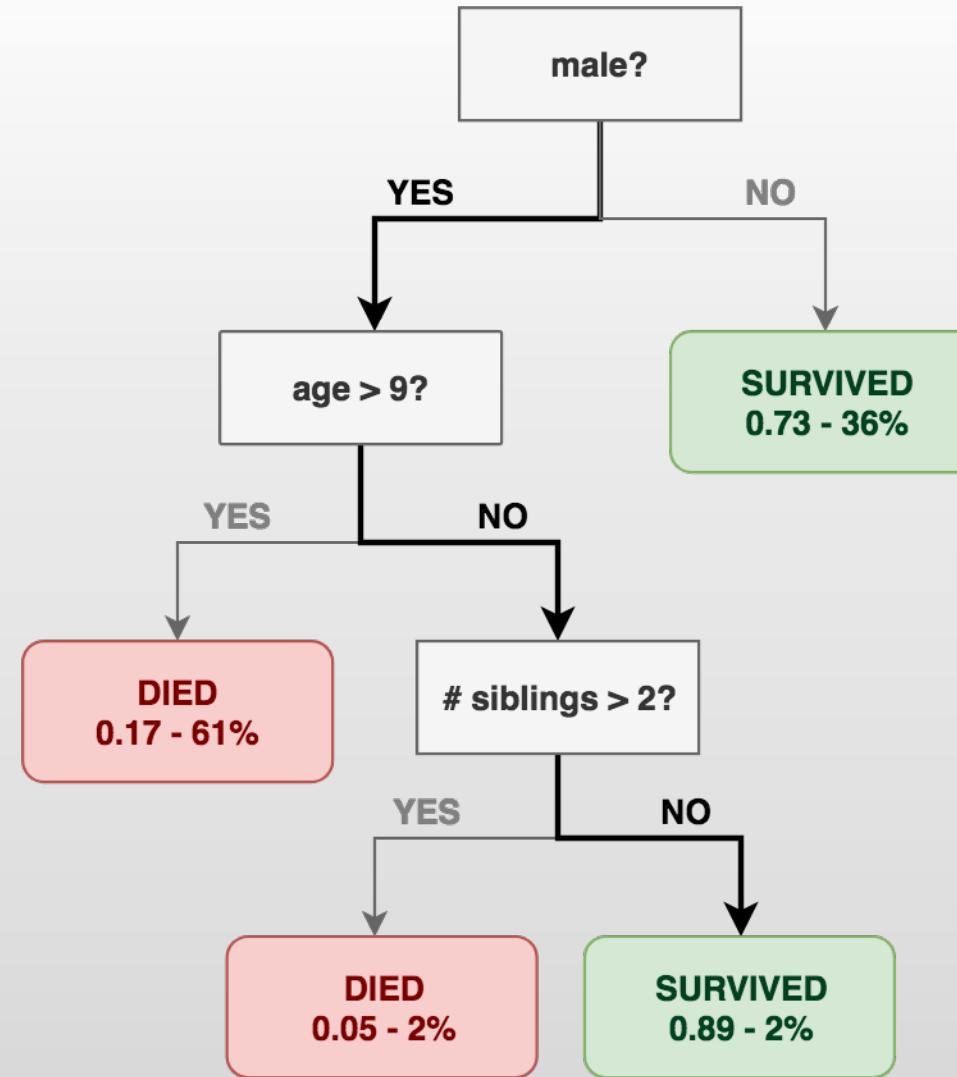


## Interpretare un albero di decisione

Maschio, 7 anni, figlio unico



**SOPRAVVISSUTO** perché  
maschio con meno di 9 anni e  
con meno di 2 fratelli



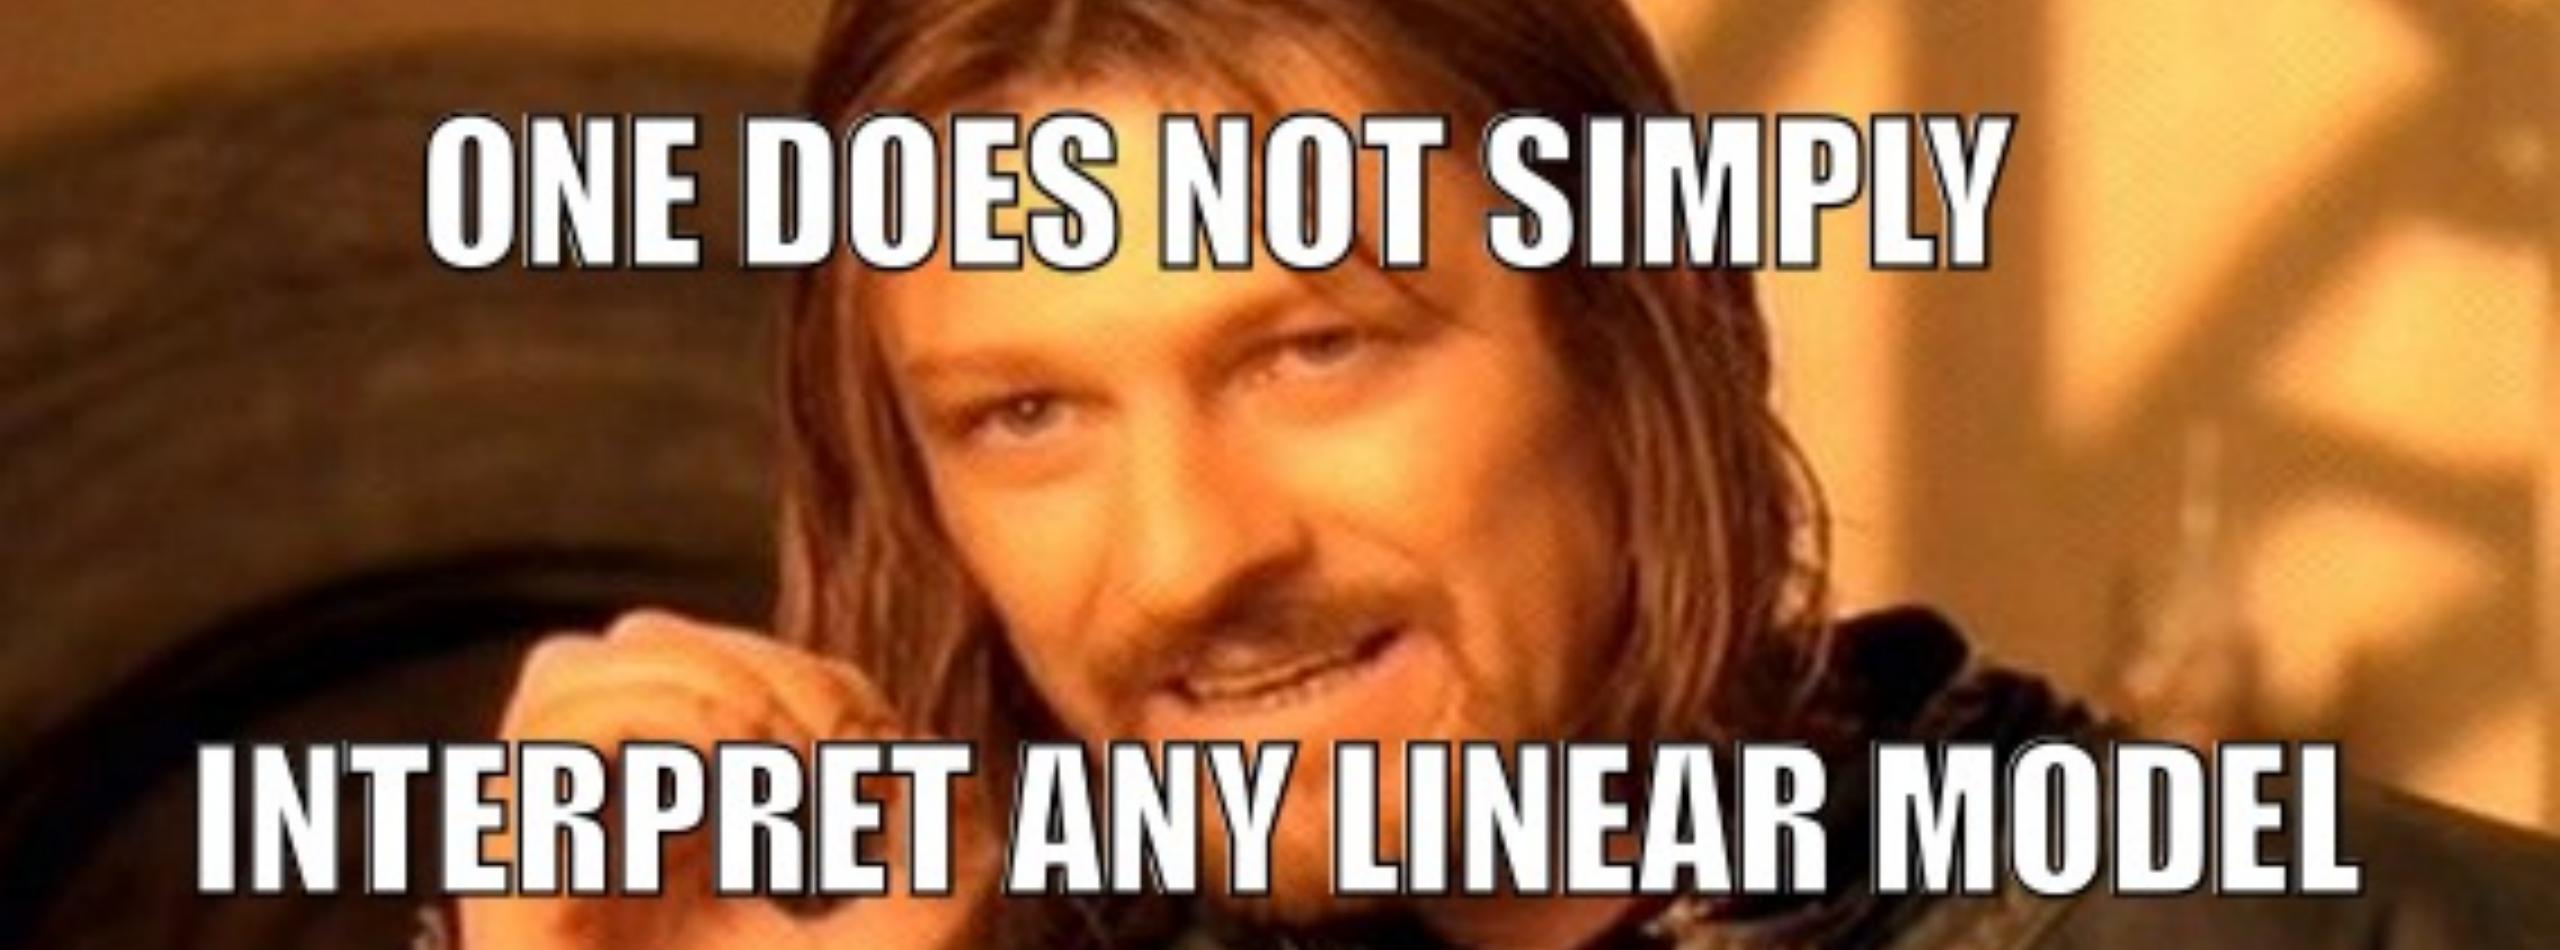
# Alberi di decisione: pro e contro

## PROS

- Ideale per catturare relazioni tra feature
- L'albero definisce implicitamente **buone spiegazioni**
- E' facile creare scenari **what-if**

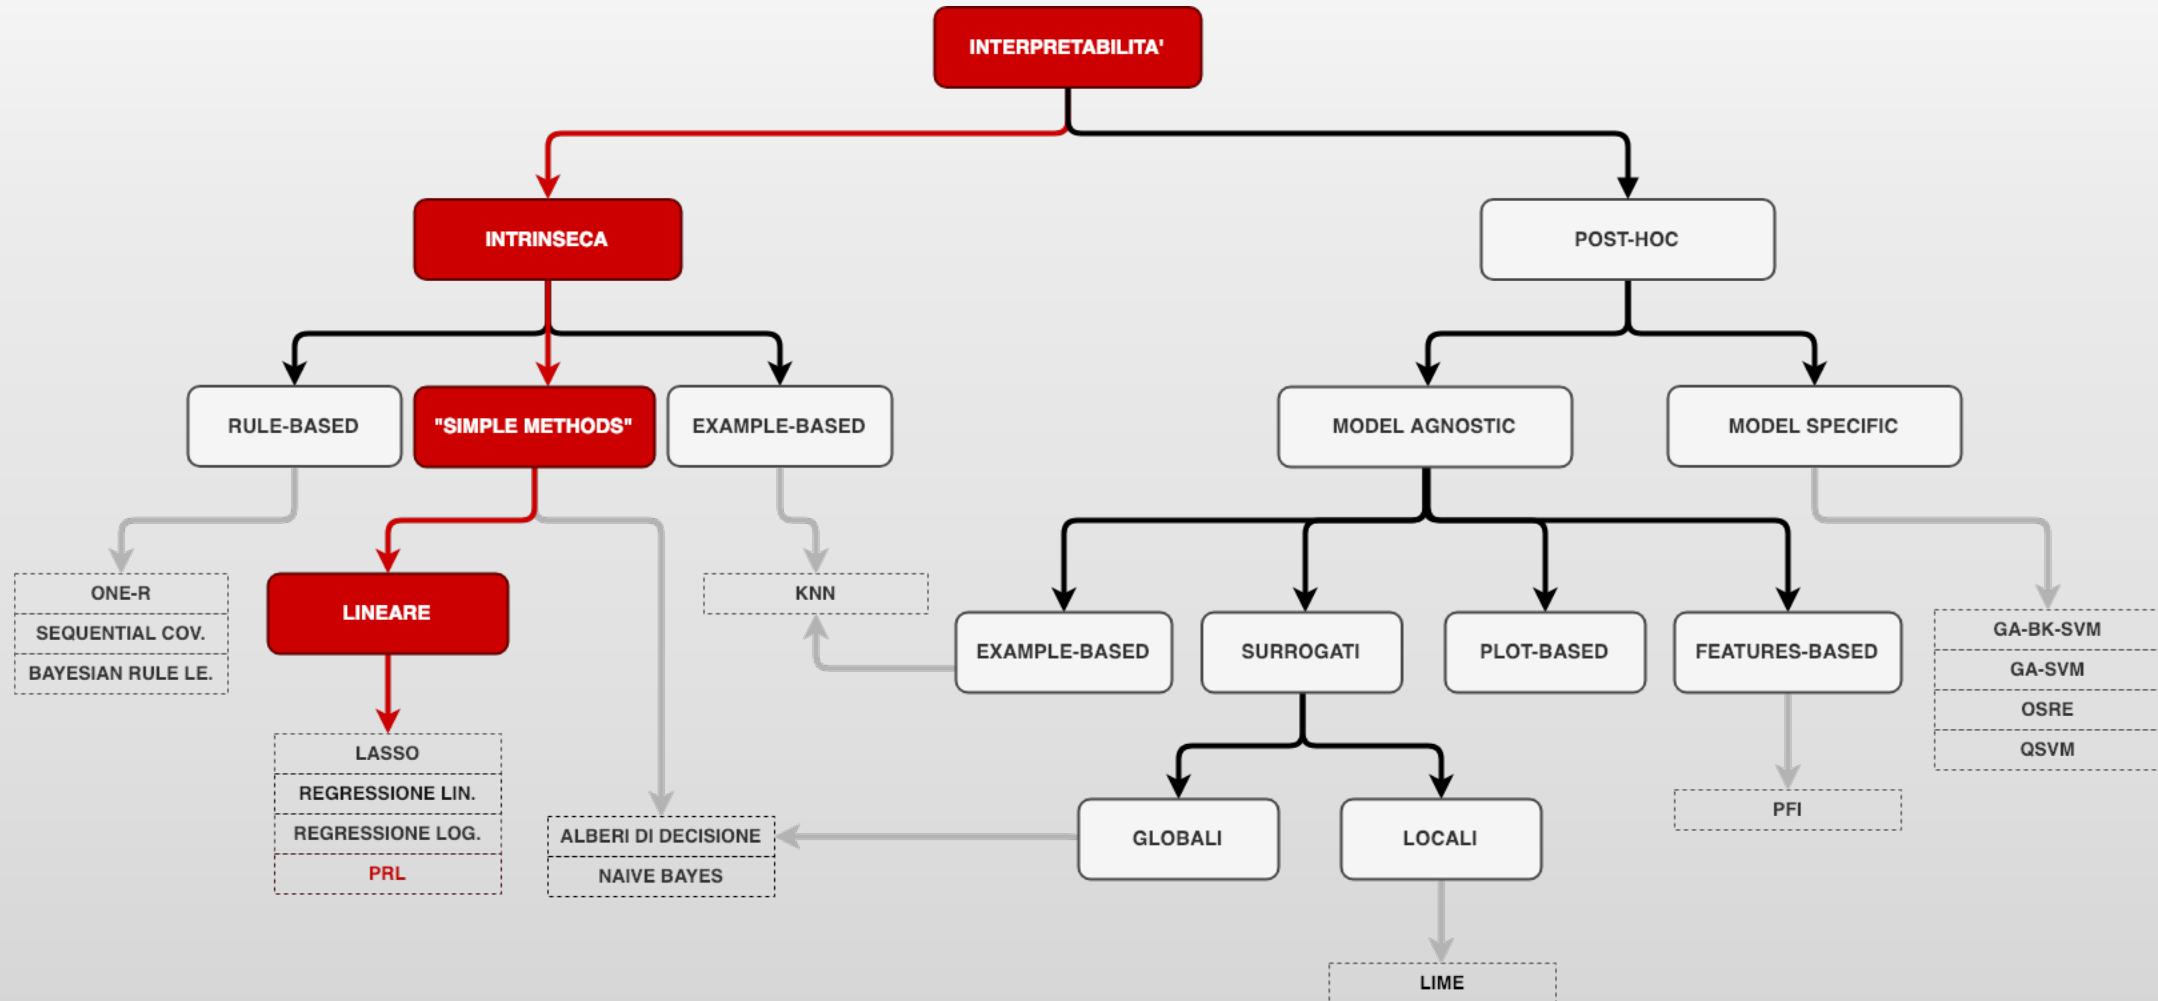
- **Falliscono** con **relazioni lineari**
- **Lack of smoothness**
- **Instabilità**
- Il numero di foglie incrementa velocemente rendendo difficile la comprensione delle regole

## CONS



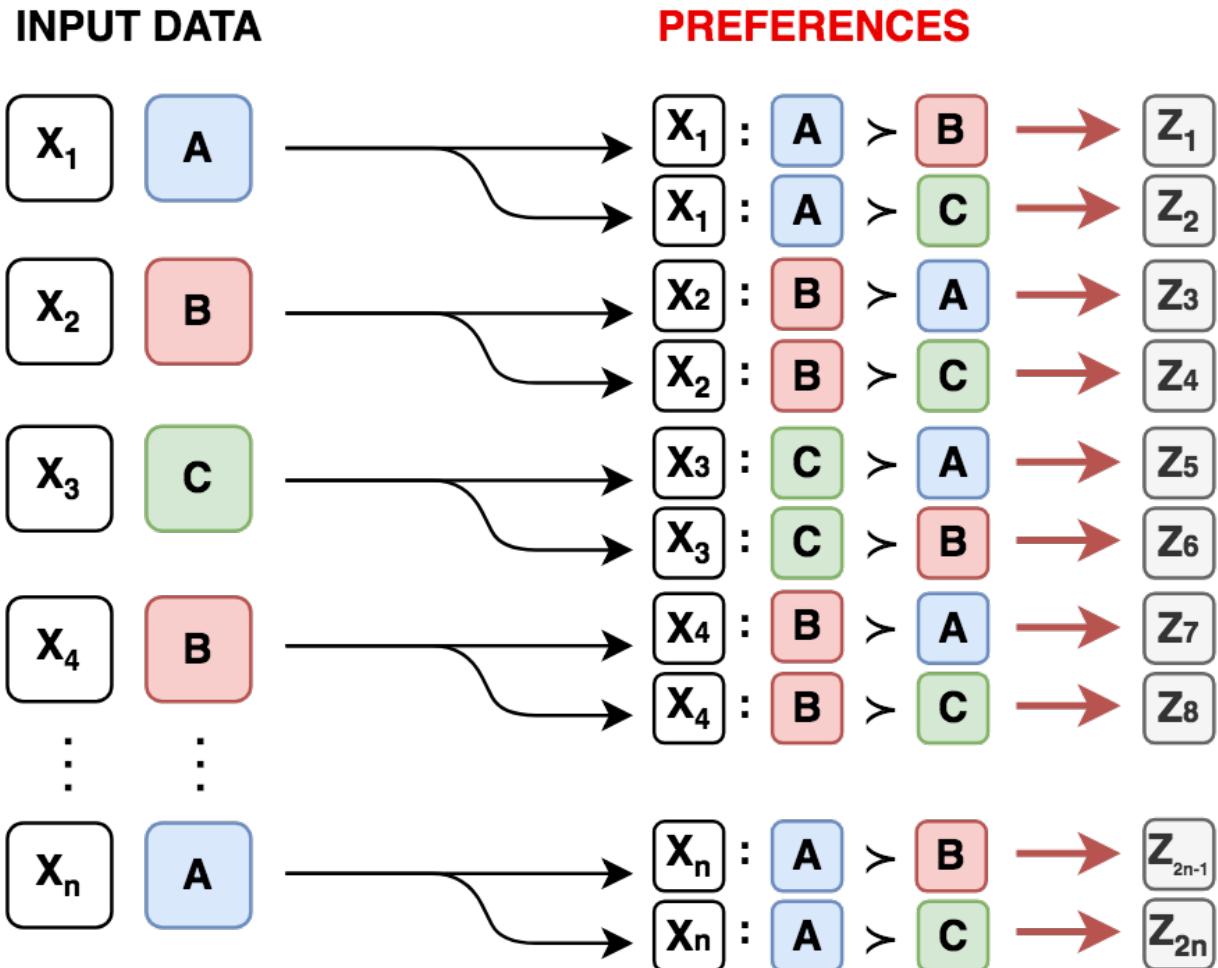
**ONE DOES NOT SIMPLY  
INTERPRET ANY LINEAR MODEL**

**PRL: Preference and Rule Learning**

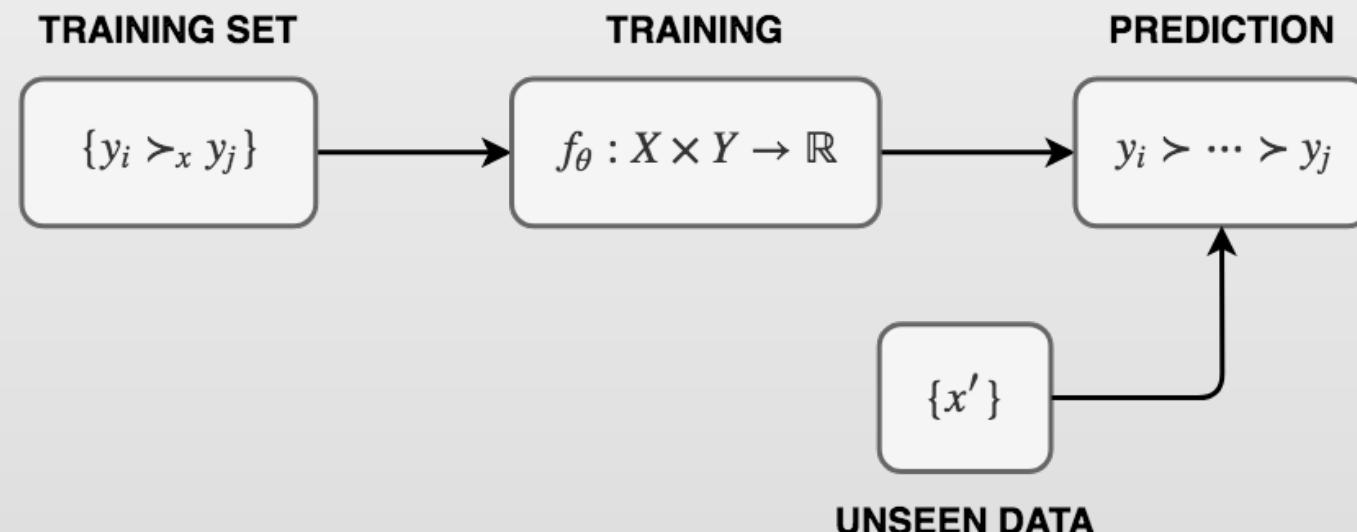


# Da classificazione a Preference Learning

- Ogni problema di classificazione può essere visto come un problema di **preference learning**



# Preference Learning in PRL



PRL apprende una funzione di scoring **lineare**  $f_{\theta} = \mathbf{w}^T \mathbf{z}$

# Come apprende PRL

PRL impara l'ipotesi che **massimizza il margine** tra preferenze

$$w \propto \sum_j \alpha_j z_j \longrightarrow \rho(z) = \sum_j \alpha_j z_j^\top z$$

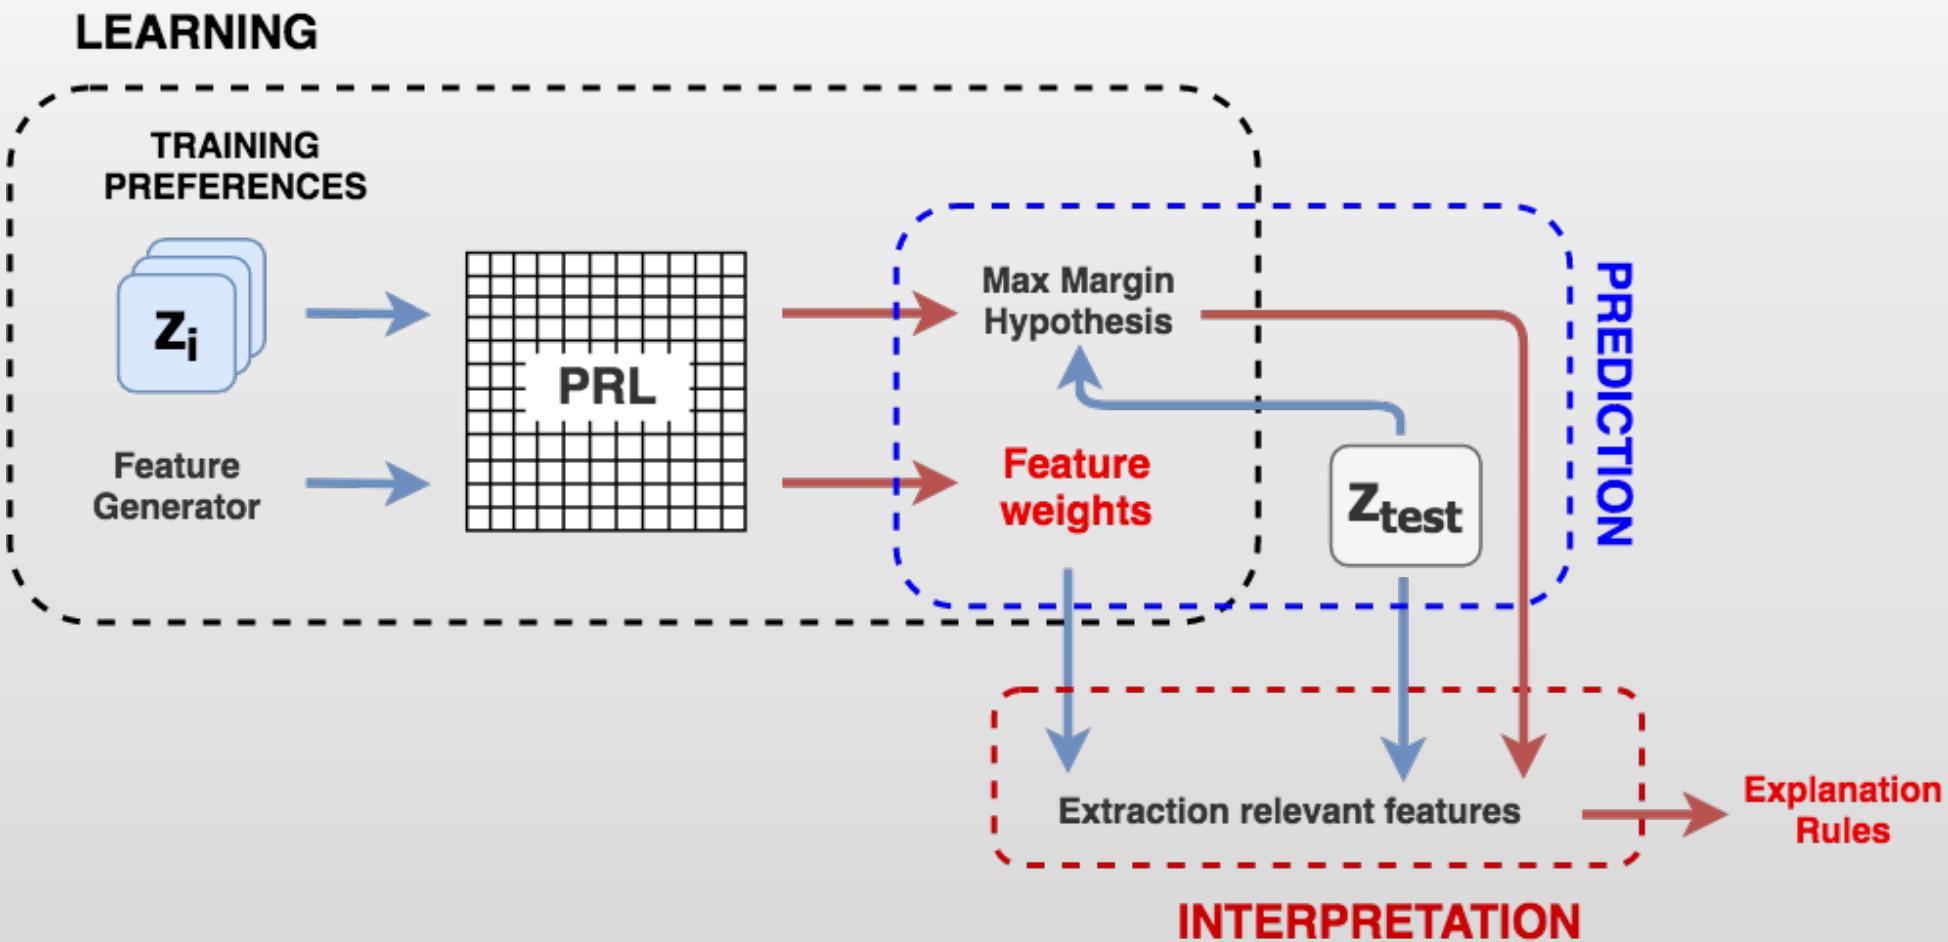
**margin**

Per scopi di feature selection PRL introduce una seconda **distribuzione  $\mu$**  (da apprendere) **sulle feature**

$$\rho(z) = \sum_j \alpha_j \sum_f \mu_f z_j[f]^\top z[f] = \sum_{j,f} q_{j,f} z_j[f]^\top z[f]$$

PRL apprende la distribuzione **q** usando la teoria dei giochi.

# Interpretabilità con PRL



# PRL: pro e contro

## PROS

- **Garanzie teoriche**
- Feature selection nel feature space
- Ideale per problemi con moltissime feature

- Nella pratica, **non particolarmente efficiente**
- Con molti esempi il **numero di preferenze** può diventare **intrattabile**
- Se il numero di feature selezionate è elevato diventa difficile l'interpretazione
- L'interpretabilità dipende da che feature si utilizzano

## CONS

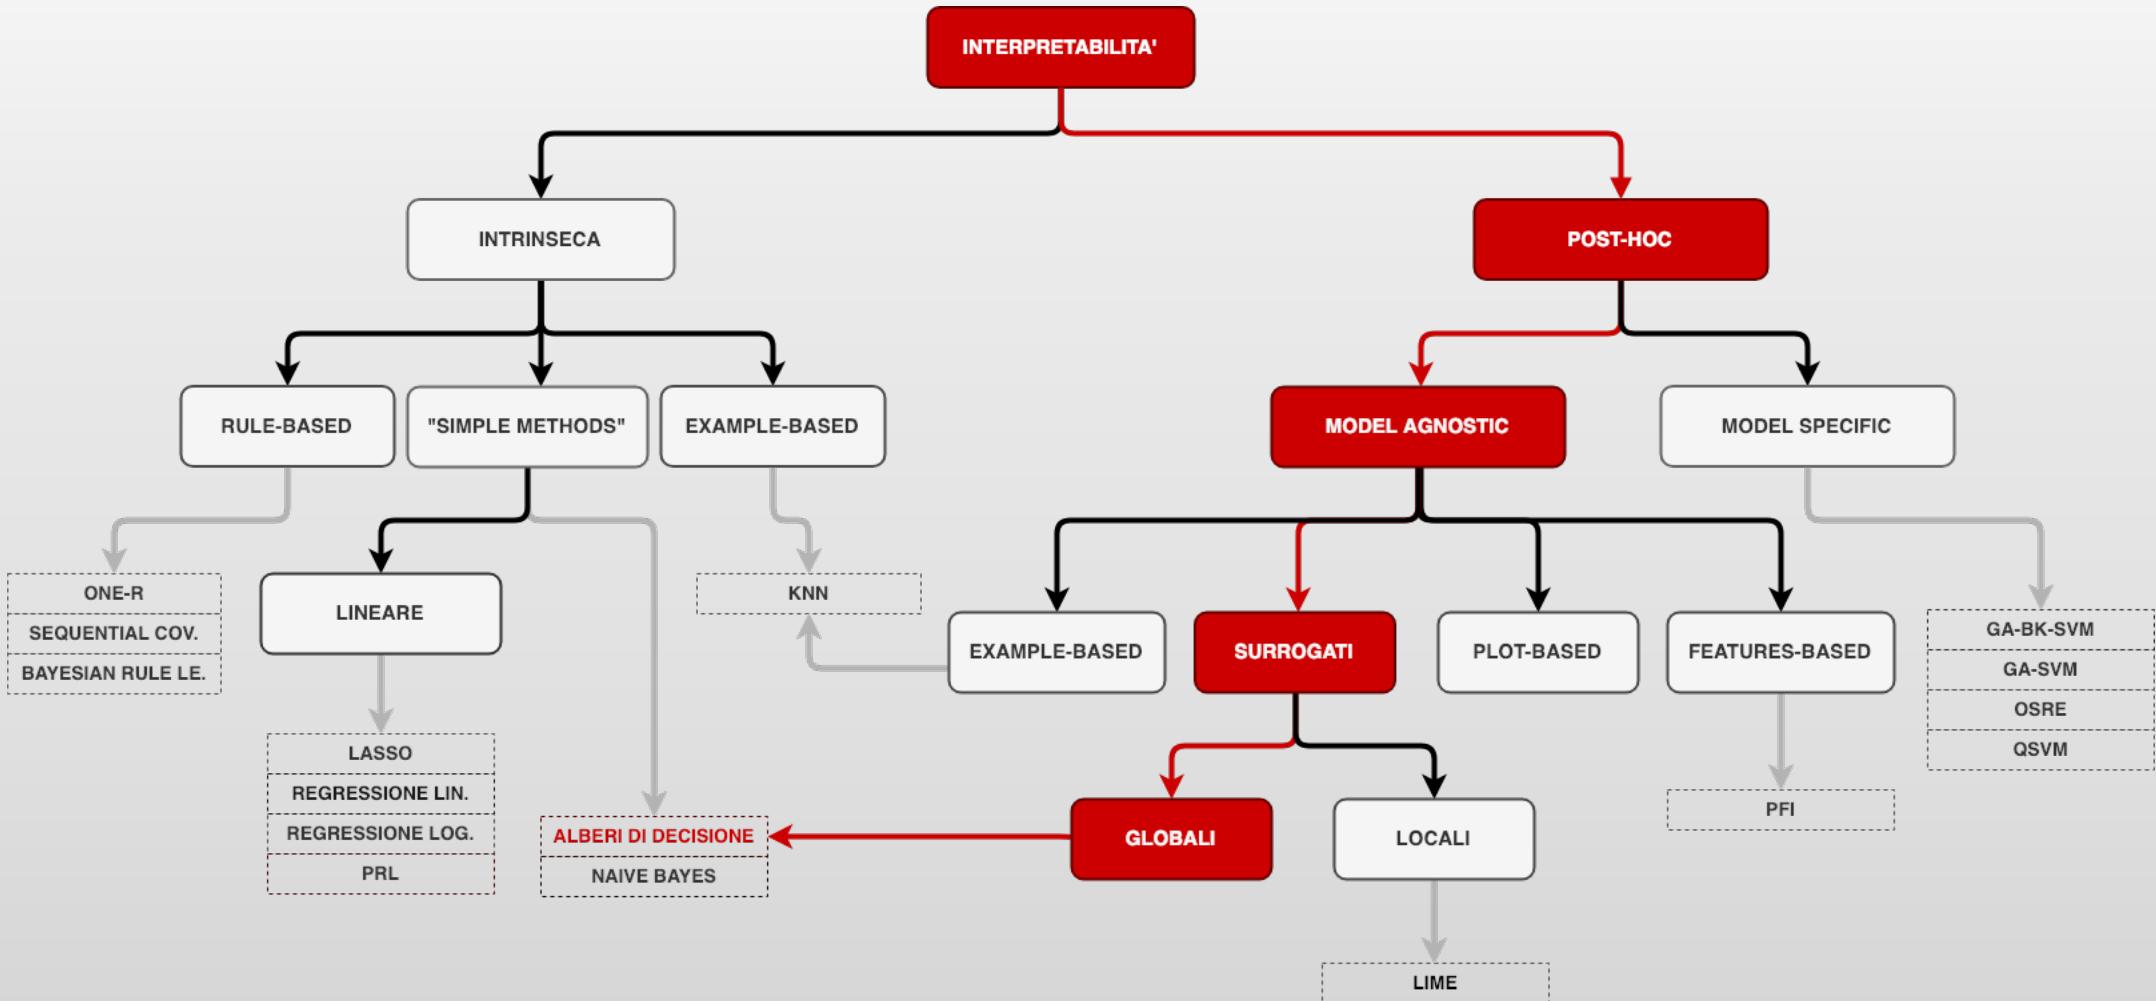


# CAN YOU INTERPRET MACHINE LEARNING MODELS

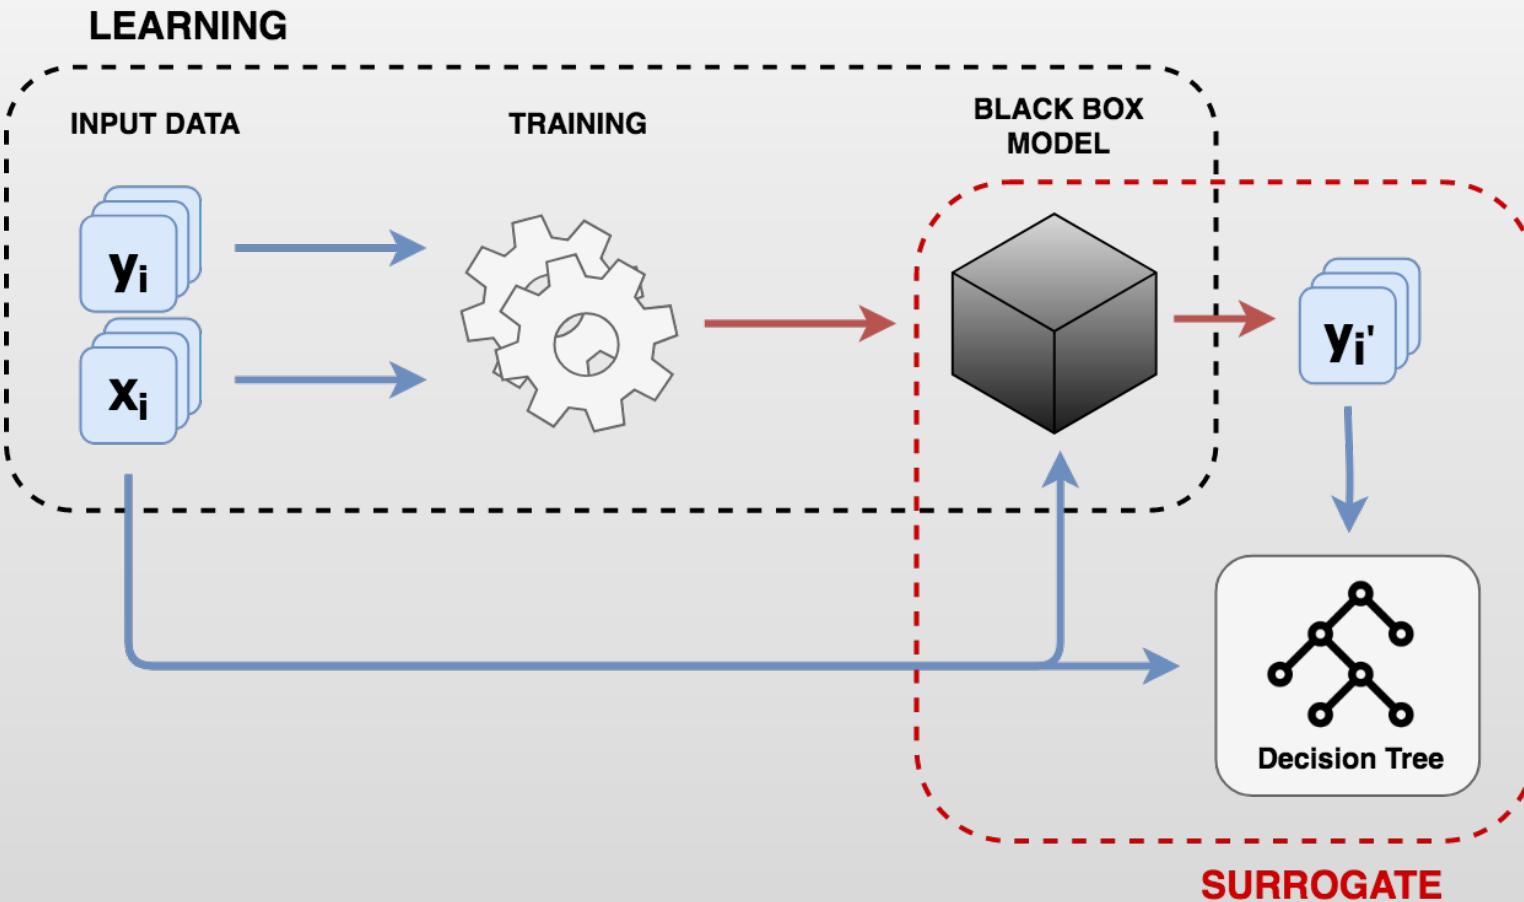
## JUST USE MORE MACHINE LEARNING

### Metodi surrogati

# Surrogati: Alberi di decisione



# Surrogati: Alberi di decisione



## EVALUATION

Valutare quanto il modello surrogato rispecchia le predizioni del modello black box

$$R^2 = 1 - \frac{\sum_i (y^* - y')^2}{\sum_i (y' - \bar{y}')^2}$$

$y^*$  output surrogato

$y'$  output black box

$\bar{y}'$  output medio BB

# Surrogati: pro e contro

## PROS

- **Flessibile**
- Approccio **intuitivo** e facile da applicare
- Alta (massima) **portabilità**

- Difficile stimare la bontà del surrogato
- Il surrogato stesso ha i suoi vantaggi/svantaggi
- Si possono trarre **conclusioni solo sul modello** e non sui dati
- La spiegazione del surrogato potrebbe non essere in linea con quella del modello di partenza

## CONS

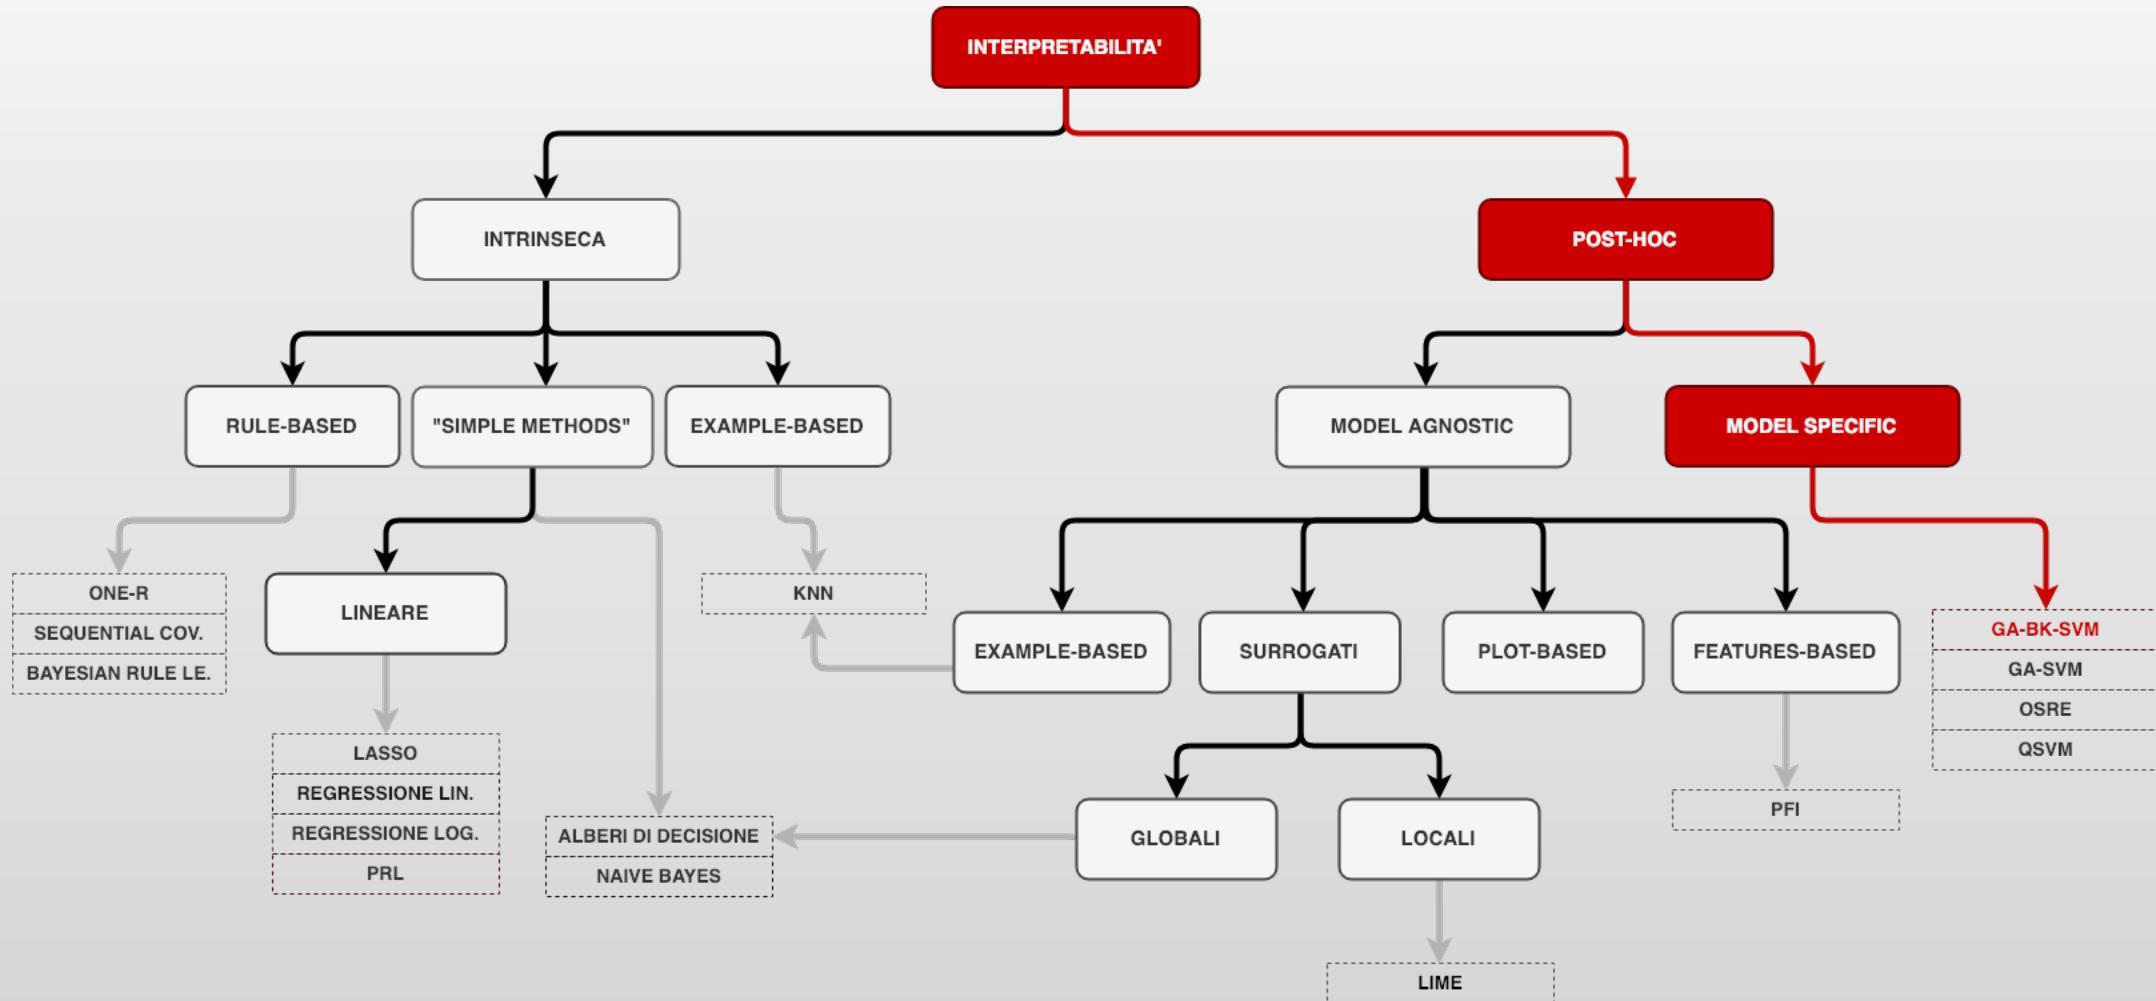


**LISTEN HERE YOU FEATURES**

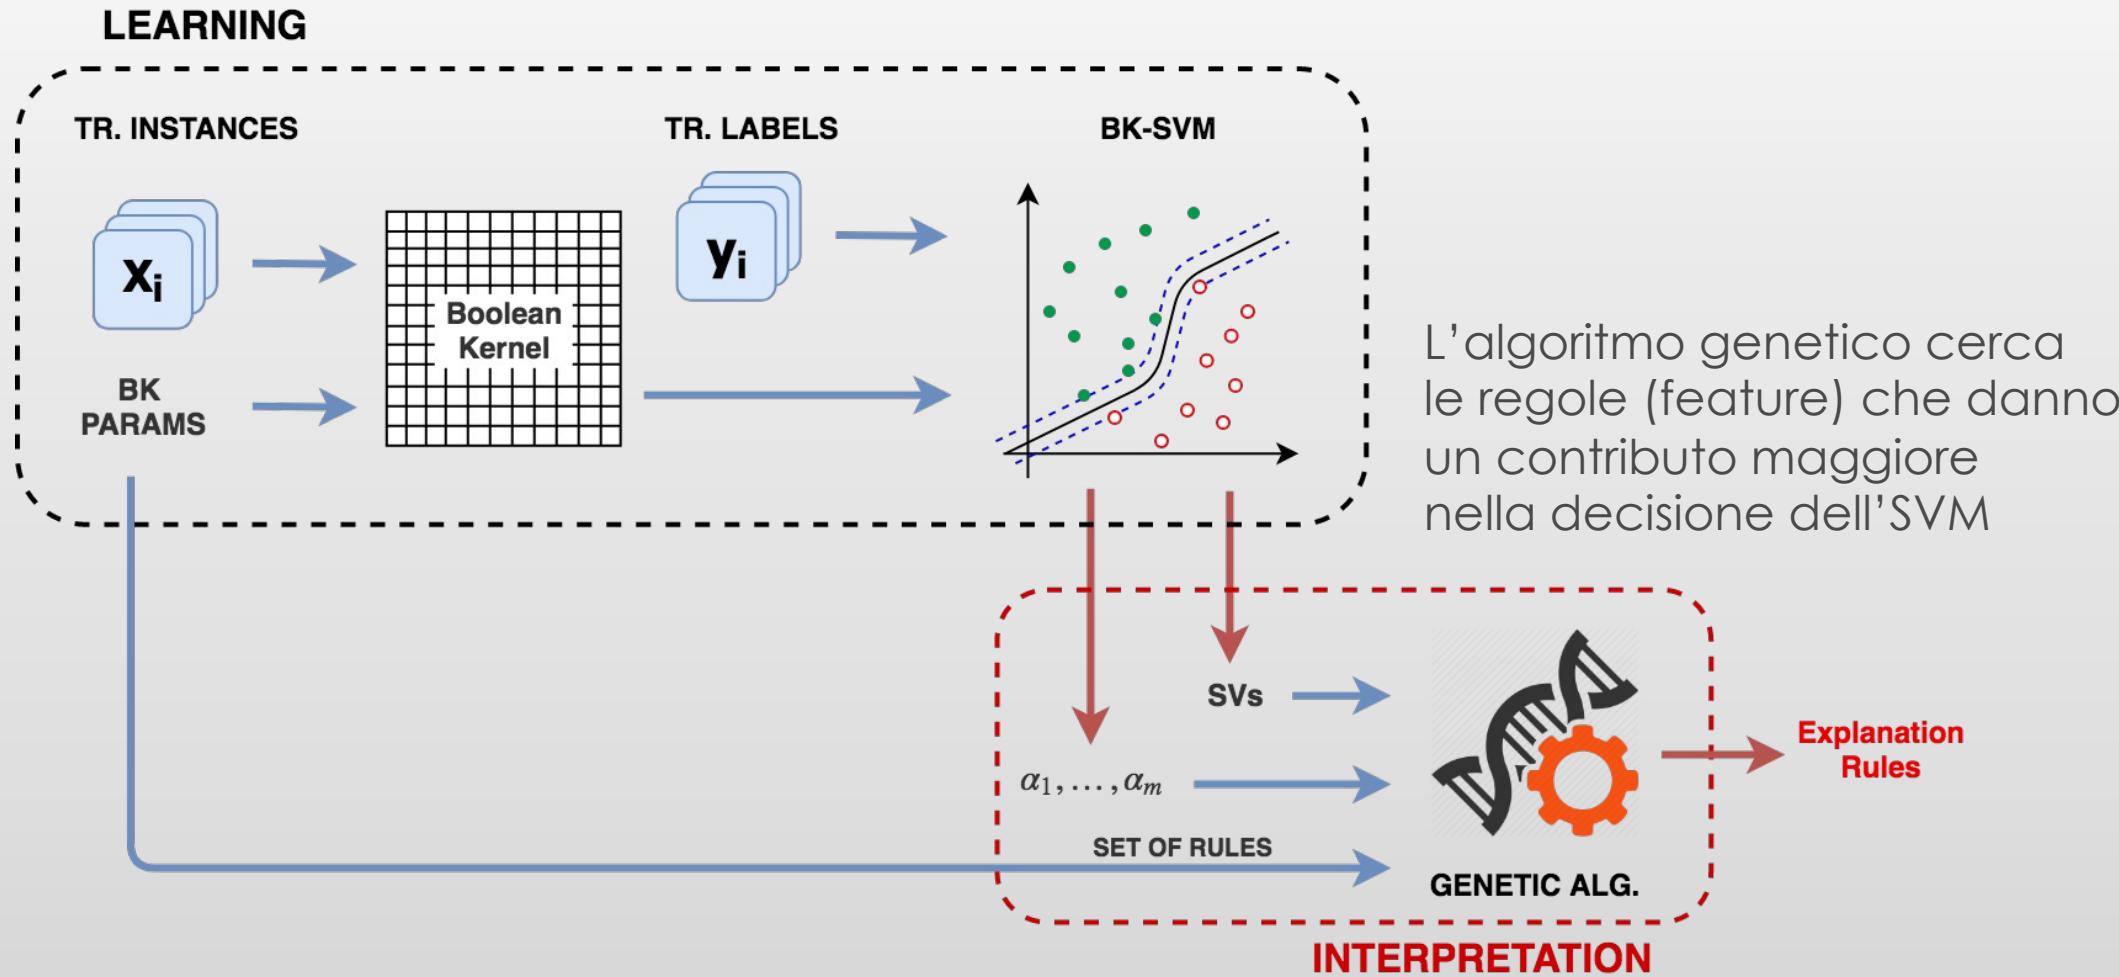
**I WILL FIND, AND I WILL USE YOU**

**GA-BK-SVM**

# GA-BK-SVM

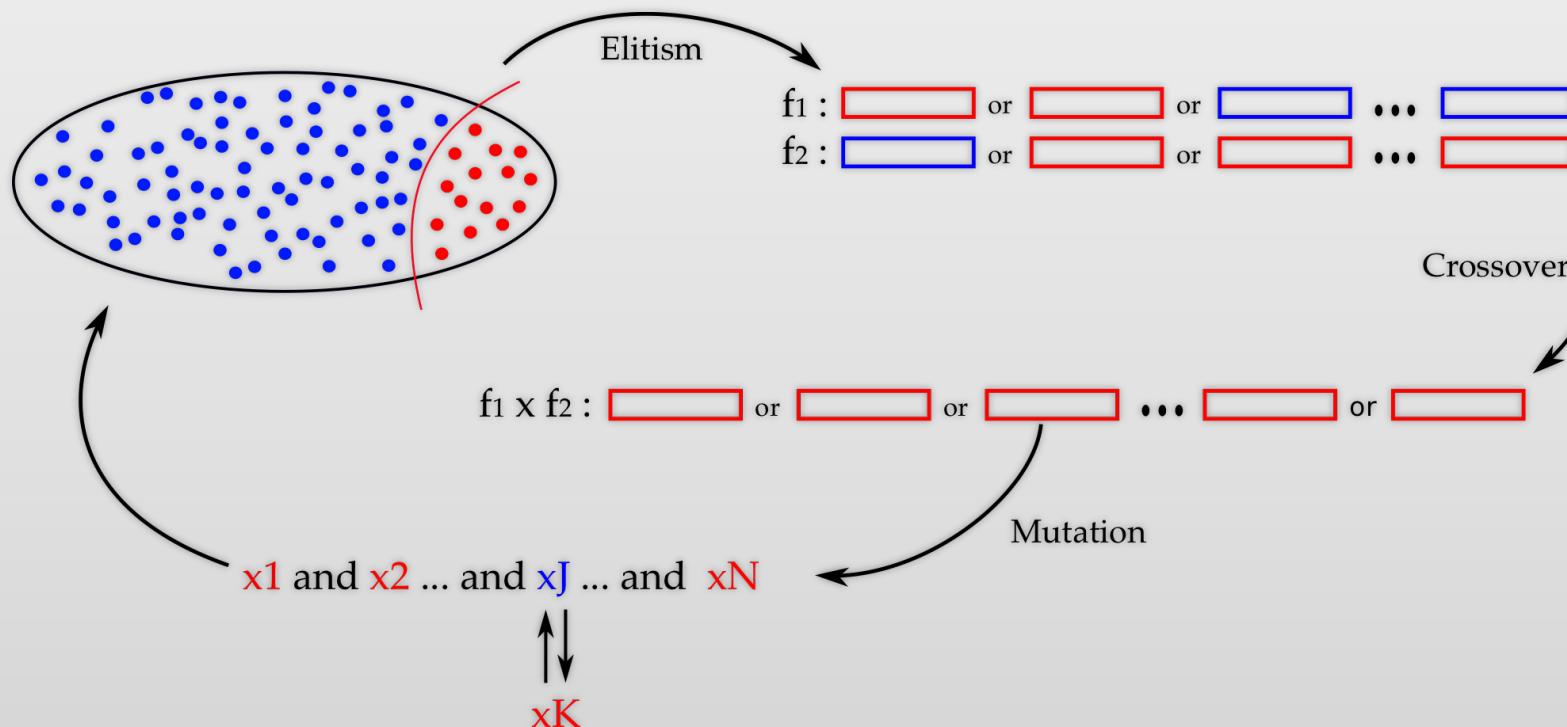


# GA-BK-SVM



# Algoritmo genetico nel “dettaglio”

- Selezione **elitista**
- Gene → mDNF formula
- **Crossover**: modifica la disgiunzione
- **Mutazione**: modifica una congiunzione



# GA-BK-SVM: pro e contro

## PROS

- Sfrutta un metodo allo stato dell'arte (SVM)
- **Teoricamente ben fondato**
- Empiricamente mostra un **ottima fedeltà** all'SVM

- **L'algoritmo genetico** non dà garanzie
- “By design” l’insieme di formule migliori è un intorno della *best rule*
- La *best rule* **potrebbe non essere facilmente interpretabile**
- In caso di feature continue, dipende molto da come si discretizza

## CONS

A photograph of a young man with brown hair, wearing a blue and white plaid shirt, looking back over his shoulder with a confused expression. Two women are visible in the background: one woman on the left is blurred, and another woman on the right is looking towards the man.

**INTERPRETABLE  
MODEL**

**ME**

**BLACK BOX  
MODEL**

**Take away messages**

# Take away messages



L'interpretabilità è una  
caratteristica spesso  
desiderabile



Ottenerla può significare  
dover rinunciare ad un po'  
di accuracy



Tema caldo nel ML perché  
legato a molte tematiche  
importanti



Creare metodi allo stato  
dell'arte "interpretabili" è  
difficile ma possibile!

# Bibliografia

**Molnar (2018)** Christoph Molnar, “*Interpretable Machine Learning – A guide for making black box models explainable*”. Leanpub book.

**Miller (2017)** Tim Miller, “*Explanation in Artificial Intelligence: Insight from the Social Sciences*”. Arxiv Preprint arXiv:1706.07269

**Polato (2018a)** Mirko Polato e Fabio Aiolfi, “*Boolean kernels for rule based interpretation of Support Vector Machines*”. Neurocomputing (Elsevier) in press.

**Polato (2018b)** Mirko Polato e Fabio Aiolfi. “*Boolean kernels for interpretable kernel machines*”. ESANN 2018.

**Polato (2019)** Mirko Polato e Fabio Aiolfi, “*Interpretable preference learning: a game theoretic framework for large margin on-line feature and rule learning*”. AAAI 2019.

## Articoli correlati

F. Poursabzi-Sangdesh et al. “*Manipulating and Measuring Model Interpretability*”. Arxiv Preprint arXiv: 1802.07810 (2018)

F. Doshi.Velez et al. “*Towards A Rigorous Science of Interpretable Machine Learning*”. Arxiv Preprint arXiv: 1702.08608 (2017)

Z. C. Lipton. “*The Mythos of Model Interpretability*”. Arxiv Preprint arXiv: 1606.03490 (2016)

# IT'S OVER



# IT'S FINALLY OVER



**Mirko Polato, PhD**

E-mail: [mpolato@math.unipd.it](mailto:mpolato@math.unipd.it)

Sito: <http://www.math.unipd.it/~mpolato>